

Transcrição da Aula "Aula 01 - Retomada do PI 5 (08.08.2026)-20260808_095014-Gravação de Reunião - Grupo A.txt"

Esta transcrição foi gerada com auxílio de IA a partir do conteúdo da aula. Embora tenha sido tratada para melhorar sua clareza e legibilidade, pode conter erros, omissões, interpretações ou atribuições incorretas de falas decorrentes da transcrição automática. Utilize-a como material de apoio, com os devidos cuidados.

Professor: Sobre o documento de hoje, vocês podem fazer ajustes e enviá-lo posteriormente. O período inicial foi reservado para que todos trabalhassem no documento, mas não há problema em complementá-lo depois. Podem apresentar o que já fizeram.

Lucas/Bruno: Recuperamos o preenchimento dos documentos que entregamos anteriormente. Temos também a apresentação e o deploy do projeto. Podemos mostrar diretamente o documento ou apresentar a solução, que permite visualizar melhor como estruturamos o trabalho.

Professor: Se conseguirem apresentar em aproximadamente 10 ou 15 minutos, podem usar o formato que considerarem mais interessante.

Bruno: Na versão final, apresentamos um site. Ele funcionou como uma representação da integração que, na solução definitiva, ocorreria no ERP da empresa. Como não implementaríamos diretamente essa integração, utilizamos uma **prova de conceito (PoC)** por meio do site. A estrutura segue o formato da apresentação do PI, incluindo problema de negócio, solução, **análise exploratória de dados (EDA)**, resultados e, ao final, uma simulação utilizando o modelo.

No sistema, executamos o modelo e selecionamos a opção de analisar o risco. A finalidade é apoiar a decisão sobre emprestar ou não determinado equipamento da empresa.

Aluno: Todo o projeto foi desenvolvido para uma choperia pertencente ao pai de um dos integrantes do grupo. A empresa realiza o empréstimo de barris de chope e chopeiras para clientes utilizarem em eventos e posteriormente devolverem. Identificamos principalmente dois problemas: **inadimplência de pagamento** e **atrasos na devolução dos equipamentos**. Em alguns casos, o cliente utiliza a chopeira durante um fim de semana e demora muito tempo para devolvê-la, afetando o giro de estoque e impedindo que o equipamento seja disponibilizado a outros clientes.

Por isso, decidimos analisar o histórico dos clientes e desenvolver uma avaliação mais automatizada no momento em que ocorre uma nova solicitação. A intenção é utilizar informações como o histórico de inadimplência para retornar uma probabilidade de o cliente apresentar problemas na transação. O modelo apresentado pelo Bruno utiliza os principais dados selecionados durante o treinamento e fornece esse retorno para auxiliar a decisão.

É um problema real e recorrente da empresa. Quando o proprietário não está presente, o funcionário frequentemente precisa entrar em contato para perguntar se determinado empréstimo ou venda deve ser liberado. Nesse primeiro momento, concentramos o projeto em **clientes recorrentes**. As variáveis explicativas foram construídas principalmente para clientes já existentes na base, com a intenção de reduzir a necessidade dessas consultas ao proprietário.

Professor: Entendi. Então, quando houver uma solicitação em que o cliente levará equipamento e determinada quantidade de chope para um evento, festa ou situação

semelhante, o objetivo é fornecer uma avaliação do risco associado à operação. A saída do modelo é simplesmente emprestar ou não emprestar, ou vocês apresentam uma probabilidade?

Aluno: Temos três classificações: **risco baixo, médio e alto**. Também apresentamos uma porcentagem associada ao risco.

Professor: Então continua sendo uma classificação, mas acompanhada da probabilidade.

Aluno: Inicialmente consideramos fornecer uma resposta binária, mas optamos pela porcentagem para relativizar a tomada de decisão. A decisão final depende também do contexto do negócio; o modelo pretende orientar, e não necessariamente determinar sozinho a ação.

Professor: Considero essa abordagem melhor. Um simples "sim" ou "não" pode ser excessivamente rígido quando o percentual está próximo do limite. Com a probabilidade, a decisão pode incorporar também a avaliação de quem conhece o negócio.

Aluno: Exatamente. Como a implementação final seria realizada no ERP, o desenvolvedor poderia definir regras de negócio. Por exemplo, poderia considerar até 35% como risco baixo e, a partir disso, estabelecer outros critérios. Portanto, também é possível transformar a saída em uma decisão binária na aplicação, sem necessariamente tornar o próprio modelo binário.

Professor: Em relação aos algoritmos, vocês chegaram a testar mais de um, estabelecer um **baseline** e definir qual seria utilizado? Como está essa parte tecnicamente?

Aluno: Sim. Era uma exigência do PI 5 testar diferentes algoritmos e compará-los. Começamos pela **regressão logística**, porque queríamos trabalhar inicialmente com um problema relativamente simples enquanto aprendíamos e implementávamos o algoritmo. O resultado foi satisfatório, mas precisávamos avançar para fazer a comparação.

Professor: Quando utilizaram regressão logística, vocês fizeram classificação binária ou multiclasse? Lembram se trabalharam com *softmax* ou *sigmoid*?

Aluno: Não lembro exatamente da implementação, mas todo o código está no GitHub, inclusive o notebook responsável por essa parte.

Professor: Os notebooks continuam executáveis?

Aluno: Sim. A execução original envolve o servidor da empresa, mas uma das nossas premissas foi salvar as principais tabelas em **CSV** para permitir a execução sem depender diretamente da conexão com o banco. Portanto, acreditamos que continuam executáveis.

Depois da regressão logística, avançamos para uma **árvore de decisão**, que apresentou melhora, e posteriormente para uma **Random Forest**, que foi o modelo escolhido. Chegamos a testar uma quarta alternativa com otimização, mas os três modelos já atendiam aos requisitos da disciplina e encerramos com a Random Forest como modelo vencedor.

Professor: Vocês possuíam histórico com rótulos para trabalhar com um algoritmo supervisionado?

Aluno: Sim. Tínhamos os dados de atrasos e outros registros históricos, embora tenha sido necessário transformá-los em rótulos adequados ao algoritmo.

Professor: Essa transformação faz parte da **engenharia de atributos**. O importante é que existia uma base histórica na qual era possível identificar clientes que efetivamente tiveram problemas e clientes que não tiveram, juntamente com características explicativas.

Qual era aproximadamente o volume de dados utilizado?

Aluno: Fizemos essa análise no notebook. Algumas tabelas tinham aproximadamente 1.100 linhas, outras 1.200 e uma delas cerca de 18 mil linhas.

Professor: Qual é a granularidade dessas linhas? Cada linha representa um cliente, uma compra ou um empréstimo?

Aluno: Há diferentes tipos de registros porque trabalhamos diretamente com a base da empresa. É uma base bastante completa e também contém estruturas que a empresa não utiliza diretamente, porque o sistema foi desenvolvido sobre uma base mais genérica. Em quantidade total, tínhamos aproximadamente **nove mil clientes**.

Professor: E em relação à quantidade de variáveis utilizadas para explicar o comportamento? Estamos falando de algo próximo de dez ou de cem variáveis?

Aluno: Aproximadamente **12 variáveis**. Em uma etapa da análise trabalhamos com cerca de mil clientes, mas, ao filtrar apenas aqueles com recorrência, chegamos a aproximadamente **200 clientes**, mantendo cerca de 12 variáveis principais.

Professor: Vocês descartaram clientes por causa da recorrência?

Aluno: Sim, recorrência de compra. Clientes com apenas uma compra não participaram da análise. Acredito que exigimos mais de duas compras. Como queríamos analisar o comportamento histórico do cliente, consideramos que uma única compra não forneceria histórico suficiente. O projeto não buscava prever clientes novos; estava direcionado aos recorrentes.

Professor: Aqui existe um ponto importante para reavaliar. Quando um modelo aprende, dependendo das variáveis explicativas, ele procura padrões que podem ser generalizados independentemente da pessoa específica. Mesmo que determinado cliente tenha feito apenas uma compra, outros clientes com perfil semelhante podem fornecer informação útil para prever seu comportamento futuro.

Tenho projetos semelhantes, por exemplo, de **propensão à compra**, em que procuramos estimar a probabilidade de uma próxima compra e o melhor produto a sugerir. Nesse caso, mantive inclusive clientes que ainda não haviam comprado, porque o comportamento e as características deles podem se assemelhar aos de outros clientes.

Assim, eliminar um cliente simplesmente porque ele realizou apenas uma operação pode não ser necessário. O aspecto central é distinguir a ausência de **variáveis explicativas** da ausência do **rótulo que se pretende prever**. Um cliente pode possuir todas as características necessárias para inferência mesmo que ainda não tenha determinado resultado registrado. Nesse caso, justamente queremos prever essa coluna de resultado.

Não sei quanto da base foi eliminado por essa decisão, mas vale reavaliar a abordagem.

Aluno: Faz sentido. É uma abordagem diferente daquela que adotamos como baseline. Tivemos essa discussão algumas vezes e percebemos que havia perda de dados, embora tenhamos optado por esse caminho naquele momento.

Professor: Quanto vocês perderam percentualmente ao excluir clientes com poucas compras?

Aluno: Em quantidade de clientes, tínhamos aproximadamente mil e acabamos trabalhando com uma base de cerca de 200.

Professor: Nesse caso, provavelmente vale rever a decisão. Estamos falando de uma redução muito grande da informação disponível. É diferente eliminar clientes porque não existe nenhum sinal explicativo e eliminar clientes porque não existe determinado rótulo.

Para dar outro exemplo, em um projeto recente utilizei aproximadamente 80 mil registros para **treinamento**, mas, na fase de **inferência**, apliquei o modelo a mais de um milhão de registros. Na inferência, o objetivo é alcançar o maior número possível de clientes. Quanto maior a população para a qual o modelo consegue produzir uma previsão útil, maior tende a ser o valor de negócio da solução.

Por isso, ao selecionar variáveis, também considero quantos clientes seriam excluídos caso determinada variável fosse obrigatória. É sempre uma relação de custo-benefício. Eliminar cerca de quatro quintos dos clientes potencialmente elegíveis para inferência é uma perda considerável.

Aluno: Esse ponto já havia surgido em conversas anteriores e o colocamos como possibilidade de evolução: revisar as variáveis explicativas e a abordagem geral para conseguir incluir também esses clientes. Precisamos fazer essa reanálise.

Professor: Perfeito. Esse é um ponto de evolução. Avaliem até que ponto o trabalho existente pode ser reaproveitado e quais aspectos precisam ser modificados. Vocês ainda podem discutir outros pontos de melhoria, mas a inclusão dos clientes que ficaram de fora é claramente um deles.

Vocês recebem a base em arquivos CSV?

Aluno: Temos um **backup do banco de dados**, uma fotografia da base em determinado momento. Fazemos as consultas em SQL e, pelo próprio programa, salvamos em CSV as principais tabelas utilizadas. Isso facilita a apresentação e evita depender de conexão com o banco durante a execução.

O repositório no GitHub está organizado e o README contém boa parte das informações do projeto. O conteúdo que inserimos no documento atual foi recuperado desse material, inclusive a descrição do problema de negócio. O backup do banco também está armazenado no repositório, mas, por conter **dados sensíveis**, o repositório está privado. O professor foi adicionado como colaborador.

Também habilitamos temporariamente o site que utiliza o modelo e dados reais.

Professor: É necessário bastante cuidado com esses dados por questões de **segurança e proteção de dados**. O backup do banco não pode ficar publicamente acessível.

Aluno: O GitHub está privado. O site está hospedado sem credencial de acesso, mas não fornece acesso ao banco de dados; utiliza apenas o modelo serializado em PKL.

Professor: Certo. Minha preocupação principal era com o backup da base. Esse material precisa permanecer protegido.

Aluno: No repositório também estão o código do site e a pasta de documentos finais, que reúne os materiais entregues na avaliação: guias, relatório final, notebook com o código, atas de reunião e demais entregáveis. Também mantemos os três modelos em arquivos PKL, embora apenas a Random Forest tenha sido utilizada no site.

Professor: Gostei do problema. Há também outra possibilidade de evolução. Vocês assistiram à apresentação sobre **Databricks**?

Alunos: Sim.

Professor: O que acharam? Alguém já conhecia?

Aluno: Parece interessante, especialmente pela possibilidade de centralizar recursos que, ao longo do curso, utilizamos de forma separada. Ainda não tivemos experiência prática suficiente com a plataforma.

Professor: A Databricks é uma plataforma que utilizo profissionalmente. Ontem vocês também conversaram com a professora Brenda, que mencionou a possibilidade de utilizá-la como ferramenta. Em termos de **empregabilidade**, considero interessante conhecer Databricks e também tecnologias como **Google BigQuery**, que têm bastante relevância no mercado.

Uma possibilidade seria utilizar a modalidade gratuita da Databricks para executar o conteúdo do projeto. Isso permitiria que vocês adquirissem experiência prática e, efetivamente conhecendo a ferramenta, pudessem mencionar essa competência no currículo. Também vale explorar os cursos e certificações disponibilizados pela plataforma.

Ainda preciso verificar se os recursos da modalidade gratuita são suficientes para todos os projetos de TG. Não quero estabelecer como requisito algo que funcione apenas para determinados grupos. Portanto, neste momento é uma **sugestão**, e não uma exigência da disciplina. Vou buscar mais informações antes de definir isso.

Aluno: No nosso caso, o site foi hospedado em uma versão gratuita do **PythonAnywhere**. Entretanto, no nível de aplicação em que estamos trabalhando, os limites da hospedagem gratuita são facilmente atingidos. Alguns grupos não conseguiram realizar o deploy porque suas aplicações excediam esses limites. Como já tenho experiência com desenvolvimento, consegui reduzir os pacotes Python e otimizar a aplicação para viabilizar a hospedagem. Por isso, tornar a solução disponível on-line talvez não possa ser uma premissa geral da disciplina.

Também mantenho no GitHub os repositórios dos projetos desenvolvidos nas diferentes disciplinas do curso. A intenção é utilizá-los como parte do repositório final do TG.

Aluno: Para encerrarmos, existe alguma orientação específica para a próxima semana? Quais seriam os próximos passos?

Professor: Vou finalizar e enviar o **manual da disciplina**, no qual serão listados os requisitos e os materiais que vocês precisarão entregar. A partir disso, vocês já poderão organizar o trabalho. Por enquanto, essa é a principal orientação.

Também vou acessar e baixar o conteúdo que vocês disponibilizaram para que eu possa analisar o material. Caso haja algum problema com o convite do repositório, entro em contato posteriormente.

Aluno: O convite foi enviado para o e-mail institucional e concede acesso como colaborador somente às pessoas envolvidas no projeto.

Professor: Certo. Se houver algum problema de acesso, aviso vocês posteriormente.

:::