





ANÁLISE PREDITIVA

Ciência de Dados para Negócios
FATEC Votorantim

Prof. **Luis Claudio**

M.Sc. Eng. Elétrica (PUC-Rio - 06)

Eng. de Computação (ITA-99)



| — DEVOPS

Prof. Luis Claudio

M.Sc. Eng. Elétrica (PUC-Rio - 06)

Eng. de Computação (ITA-99)

DEVOPS

DO DESENVOLVIMENTO À PRODUÇÃO


Por décadas, **Desenvolvimento e Operações** foram tratados como mundos separados. Tradicionalmente, o Desenvolvimento **construía e modificava o software** e, em determinados momentos, uma **nova versão** era entregue à equipe de Operações, responsável por **implantá-la e mantê-la em produção**.

Desenvolvimento

- Criar e evoluir o software
- Novas funcionalidades
- Correções e manutenção
- Mudanças frequentes

Operações

- Manter o SW em produção
- Disponibilidade e estabilidade
- Segurança e desempenho
- Controle das mudanças



DEVOPS

A BRAVE NEW WORLD!

Mas o mundo mudou...

- Softwares passaram a evoluir continuamente
- Novas funcionalidades precisavam chegar **mais rápido aos usuários**
- Correções **não podiam esperar** longos ciclos de entrega
- O mercado passou a exigir **velocidade e adaptação**

Mas havia um problema...

- Desenvolvimento e Operações trabalhavam de forma muito separada
- Cada entrega envolvia processos, comunicação e procedimentos “burocráticos”
- Mudanças mais frequentes poderiam significar **maior risco para produção**

DEVOPS

DESENVOLVIMENTO (DEV) E OPERAÇÕES (OPS)

DevOps surge como uma abordagem para aproximar **Desenvolvimento (Dev)** e **Operações (Ops)**, reduzindo as barreiras entre essas áreas.

A ideia central:

- Maior **colaboração** entre Dev e Ops
- **Responsabilidade compartilhada** pelo **ciclo de entrega**
- **Automação** de processos repetitivos
- Entregas mais **frequentes, rápidas e confiáveis**

DevOps não é uma ferramenta: **é uma cultura e um conjunto de práticas** para integrar desenvolvimento e operações.

DEVOPS

HISTÓRIA

Um pouco de contexto histórico...

- **2001** — **Manifesto Ágil** como antecedente importante.
- **2007–2008** — discussões de **Patrick Debois** sobre a aproximação entre desenvolvimento e operações.
- **2009** — apresentação da Flickr, “**10+ Deploys per Day**”, demonstrando integração entre Dev e Ops para entregas frequentes.
- **2009** — primeiro **DevOpsDays**, organizado por Patrick Debois em Ghent, Bélgica.


A partir daí, o termo **DevOps** se consolida e o movimento ganha força.

DEVOPS

O CICLO INFINITO

DevOps propõe um ciclo contínuo e integrado:

... → *Plan* → *Code* → *Build* → *Test* → *Release* → *Deploy* → *Operate* → *Monitor* → ...



DEVOPS

UM ECOSSISTEMA DE FERRAMENTAS

A cultura DevOps impulsionou a adoção de ferramentas para automatizar diferentes etapas do ciclo de software.

Finalidade	Para que serve	Exemplos
Versionamento	Controlar alterações no código e manter o histórico de suas diferentes versões	Git, GitHub, GitLab
CI/CD	Automatizar processos de integração, testes e entrega de novas versões	Jenkins, GitHub Actions, GitLab CI/CD
Containers	Empacotar uma aplicação com suas dependências, facilitando sua execução em diferentes ambientes	Docker
Orquestração	Automatizar a implantação, execução e gerenciamento de aplicações em containers	Kubernetes
Infraestrutura como Código (IaC)	Criar e configurar infraestrutura por meio de arquivos de código, de forma automatizada e reproduzível	Terraform, Ansible*
Monitoramento	Acompanhar o funcionamento das aplicações e da infraestrutura em produção	Prometheus, Grafana



II – MLOPS

Prof. Luis Claudio

M.Sc. Eng. Elétrica (PUC-Rio - 06)

Eng. de Computação (ITA-99)

MLOPS

DE DEVOPS PARA MLOPS


Em Machine Learning, colocar uma solução em produção envolve **mais do que código**. **Se os dados mudarem, o modelo muda**, mesmo sem que uma linha de código do seu notebook mude!

E os dados sempre mudam... 😞

No **desenvolvimento tradicional**:




Código



Software

Em **Machine Learning**:



Código



Dados



Experimentos



Modelo

MLOPS

DADO MUDA, INFERÊNCIA MUDA

No **software tradicional**, se o código e o ambiente não mudarem, **seu comportamento não muda**.

Em um **modelo de Machine Learning**, mesmo sem alterar o código ou o próprio modelo, **seu desempenho pode mudar**, porque os dados sobre os quais ele opera mudam.

Atenção:

- Durante a **inferência**, os parâmetros aprendidos permanecem fixos: **mudam os dados e as predições, não o modelo**.
- Mas, se novos dados levarem ao **retreinamento**, novos parâmetros serão aprendidos, dando origem a **uma nova versão do modelo**.

MLOPS

O QUE É?

MLOps (Machine Learning Operations) é um conjunto de **práticas, processos e tecnologias** para gerenciar o ciclo de vida de modelos de Machine Learning de forma **reprodutível, automatizada e confiável**.

MLOps = Machine Learning + Desenvolvimento + Operações

Isso envolve:


- **Experimentar** — diferentes dados, parâmetros e modelos
- **Reproduzir** — saber exatamente como um resultado foi obtido
- **Implantar** — levar modelos para produção
- **Monitorar e Evoluir** — **acompanhar o desempenho e gerenciar novas versões**

MLOps não trata apenas de colocar um modelo em produção, **mas de gerenciar todo o seu ciclo de vida**.

MLOPS

O CICLO DE VIDA DE MACHINE LEARNING

Um modelo não termina quando o treinamento termina.



MLOPS

OS DESAFIOS

Como gerenciar tudo isso na prática?

- **Dados** — Quais dados foram utilizados?
- **Código** — Qual versão produziu o resultado?
- **Experimentos** — Quais configurações foram testadas?
- **Parâmetros** — Como o modelo foi treinado?
- **Métricas** — Como o desempenho foi medido?
- **Modelos** — Qual versão foi escolhida e por quê?
- **Produção** — Qual modelo está efetivamente em uso?
- **Monitoramento** — **O modelo continua apresentando o desempenho esperado?**



III – MLFLOW

Prof. Luis Claudio

M.Sc. Eng. Elétrica (PUC-Rio - 06)

Eng. de Computação (ITA-99)

MLFLOW

MLFLOW NA PRÁTICA

MLflow é uma plataforma **open source** para gerenciar o ciclo de vida de aplicações e modelos de Machine Learning.

Ele ajuda a **organizar, rastrear e gerenciar** o processo que vai da experimentação à operacionalização de modelos.

Ajuda a:

- Registrar **experimentos**
- Armazenar **parâmetros, métricas e artefatos**
- Comparar diferentes **runs**
- **Registrar, versionar e gerenciar** modelos
- Apoiar o processo de **deploy e operação**

MLOps é a disciplina. MLflow é uma das plataformas que ajudam a colocá-la em prática.

MLFLOW EXPERIMENTS



Experiments



GenAI apps & agents

Build a Generative AI application or agent



Forecasting Preview

Build a forecasting model using AutoML



Classification

Build a classification model using AutoML



Regression

Build a regression model using AutoML



Custom model training

Train a custom classical or DL model



Only my experiments

Compare (0)

Name	Created by	Last modified ↕	Location	
customer_itv_2021	Inteligência Corporativa	2026-08-14 15:33:13 -03	/Shared/lc_experiments/customer_itv/customer_itv...	
customer_itv_2016	Inteligência Corporativa	2026-08-10 18:55:56 -03	/Shared/lc_experiments/customer_itv/customer_itv...	
customer_itv	Inteligência Corporativa	2026-08-06 10:39:08 -03	/Shared/customer_itv	
customer_itv_2020	Inteligência Corporativa	2026-07-29 13:24:14 -03	/Shared/lc_experiments/customer_itv/customer_itv...	
customer_itv_2018	Inteligência Corporativa	2026-07-29 13:17:47 -03	/Shared/lc_experiments/customer_itv/customer_itv...	
customer_itv_2019	Inteligência Corporativa	2026-07-29 13:11:29 -03	/Shared/lc_experiments/customer_itv/customer_itv...	
customer_itv_2022	Inteligência Corporativa	2026-07-29 12:15:24 -03	/Shared/lc_experiments/customer_itv/customer_itv...	
customer_itv_2023	Inteligência Corporativa	2026-07-29 11:38:11 -03	/Shared/lc_experiments/customer_itv/customer_itv...	
customer_itv_0	Inteligência Corporativa	2026-07-28 22:50:13 -03	/Shared/lc_experiments/customer_itv/customer_itv...	
nicho_kmeans	Luís Claudio dos Santos	2026-05-03 11:17:16 -03	/Shared/lc_experiments/customer_niche_classificat...	

MLFLOW RUNS



customer_ltv_2021 Machine learning

Runs Models Traces

metrics.rmse < 1 and params.model = "tree" All time State: Active Datasets Sort: Created Columns Group by + New run

	Run Name	Created	Duration	Source	Models	Metrics	Parameters
						accuracy accuracy_toj	balanceamento features_utilizad janela_observaci janela_observaci
	catboost_all_features_C8_...	5 hours ago	14.0s	4.1_train...	sandbox.external_luis_sant...	0.6299008187445916 0.856752978...	Com balanc... 140 60 -
	catboost_all_features_C6_...	4 days ago	13.3s	4.1_train...	sandbox.external_luis_sant...	0.6419432227109156 0.862255097...	Com balanc... 140 60 -
	catboost_top_85_C6_JO60...	4 days ago	10.6s	4.1_train...	sandbox.external_luis_sant...	0.6851259496201519 0.891709982...	Sem balance... 85 60 -
	catboost_top_85_JO60d_...	4 days ago	10.8s	4.1_train...	sandbox.external_luis_sant...	0.6320805011328802 0.862854858...	Com balanc... 85 60 -
	catboost_top_85_JO60d_...	4 days ago	10.6s	4.1_train...	sandbox.external_luis_sant...	0.6320805011328802 0.862854858...	Com balanc... 85 60 -
	catboost_top_85_JO60d_...	4 days ago	13.0s	4.1_train...	sandbox.external_luis_sant...	0.6374783419965347 0.860189257...	Com balanc... 85 60 -
	catboost_top_85_JO60d_...	4 days ago	11.0s	4.1_train...	sandbox.external_luis_sant...	0.6433426629348261 0.851592696...	Com balanc... 85 60 -
	catboost_top_85_JO30d_...	7 days ago	11.5s	4.1_train...	sandbox.external_luis_sant...	0.6432997433811104 0.866370407...	Com balanc... 85 30 -
	catboost_top_85_JO30d_...	7 days ago	10.9s	pipeline...	sandbox.external_luis_sant...	0.6695249421042749 0.889340927...	Sem balance... 85 30 -
	catboost_top_85_JO15d_...	7 days ago	10.7s	pipeline...	sandbox.external_luis_sant...	0.552837820975898 0.814539961...	Com balanc... 85 15 -
	catboost_top_85_JO15d_...	7 days ago	10.6s	4.1_train...	sandbox.external_luis_sant...	0.5985415108451758 0.851096983...	Com balanc... 85 15 -
	catboost_top_85_JO60d_...	7 days ago	11.5s	4.1_train...	sandbox.external_luis_sant...	0.6494260544580887 0.858782701...	Com balanc... 85 60 -
	catboost_top_85_JO1_HP...	8 days ago	12.9s	4.1_train...	sandbox.external_luis_sant...	0.6351744186046512 0.867402219...	Com balanc... 85 - 1
	catboost_top_85_JO1_HP...	8 days ago	10.7s	pipeline...	sandbox.external_luis_sant...	0.6337869978858351 0.867666490...	Com balanc... 85 - 1
	catboost_top_85_JO2_HP...	8 days ago	11.5s	4.1_train...	sandbox.external_luis_sant...	0.6785094163216242 0.889141178...	Com balanc... 85 - 2
	catboost_top_85_JO2_HP...	12 days ago	11.7s	pipeline...	sandbox.external_luis_sant...	0.6796012577774805 0.887870475...	Com balanc... 85 - 2
	catboost_top_85_JO2_HP...	12 days ago	10.6s	pipeline...	sandbox.external_luis_sant...	0.678731518030374 0.886465511...	Com balanc... 85 - 2
	catboost_top_85_JO2_HP...	13 days ago	10.7s	4.1_train...	sandbox.external_luis_sant...	0.6779229480737018 0.884891122...	Com balanc... 85 - 2
	catboost_top_85_JO2_HP...	15 days ago	11.3s	4.1_train...	sandbox.external_luis_sant...	0.6790619765494137 0.885360134...	Com balanc... 85 - 2
	catboost_top_85_JO2_HP...	16 days ago	10.8s	4.1_train...	sandbox.external_luis_sant...	0.6769179229480737 0.884690117...	Com balanc... 85 - 2
	catboost_top_85_JO2_HP...	16 days ago	10.4s	4.1_train...	sandbox.external_luis_sant...	0.6737279613863377 0.883555674...	Com balanc... 85 - 2

Show more columns (60 total)

MLFLOW

RUNS DETAILS



Experiments > /Shared/lc_experiments/customer_ltv/customer_ltv_2021 > Runs >

catboost_all_features_C8_JO60d_HP365d_V1 [Send feedback](#)

Model registered [🔗](#) ⋮

[Reproduce Run](#)

[Analyze Run](#)

[Overview](#) [Model metrics](#) [System metrics](#) [Traces](#) [Artifacts](#)

Run details

Description	CatBoost LTV all_features iterations=500 depth=6 learning_rate=0.05 l2_leaf_reg=3 🔗		
Created at	Aug 14, 2026, 03:33 PM		
Created by	Inteligência Corporativa		
Status	🟢 Finished		
Run ID	b9aeb8c70c2140219829312c4f31671c 🔗		
Duration	14.0s		
Dataset used	—		
Type	Training		
Tags	modelo_vencedor: Com balanceamento model_type: CatBoost 🔗		
Source	4.1_train_catboost_ltv		
Model registered	sandbox.external_luis_santos.ltv_classification v42		

Artifacts

[View all](#) →

- model
 - metadata
 - MLmodel
 - conda.yaml
 - input_example.json
 - model.cb
 - python_env.yaml
 - requirements.txt
 - serving_input_example.json
 - features_selecionadas.json

Metrics (21)

Search metrics			
Metric	Latest	Min	Max
f1_classe_4	0.22492401215805471	0.22492401215805471	0.22492401215805471
score_selecao	0.2675314414704088	0.2675314414704088	0.2675314414704088
recall_classe_5	0.16666666666666666	0.16666666666666666	0.16666666666666666
recall_classe_4	0.19576719576719576	0.19576719576719576	0.19576719576719576
recall_classe_3	0.5264735264735265	0.5264735264735265	0.5264735264735265

Parameters (21)

Search parameters	
Parameter	Value
loss_function	MultiClass
venda_referencia	1
top_n_features	all
test_size	0.2
registros_treino	60091

</> Python



▶ Run

```
# Importar bibliotecas
import mlflow
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, f1_score
from sklearn.model_selection import train_test_split

# Definir parâmetros da execução
test_size = 0.20
random_state = 42

# Definir hiperparâmetros do modelo
n_estimators = 100
max_depth = 5

# Definir identificação no MLflow
experiment_name = "meu_experimento"
run_name = "random_forest_01"
```

</> Python



Run

```
# Preparar os dados usando os parâmetros definidos
X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=test_size,
    random_state=random_state
)

# Construir o modelo usando os hiperparâmetros definidos
modelo = RandomForestClassifier(
    n_estimators=n_estimators,
    max_depth=max_depth,
    random_state=random_state
)

# Treinar o modelo
modelo.fit(X_train, y_train)

# Realizar as previsões
y_pred = modelo.predict(X_test)

# Calcular as métricas
accuracy = accuracy_score(y_test, y_pred)
f1 = f1_score(y_test, y_pred)
```

Python



Run

```
# Definir o Experiment onde as Runs serão agrupadas
mlflow.set_experiment(experiment_name)

# Iniciar uma nova Run
with mlflow.start_run(run_name=run_name):

    # Registrar os parâmetros da execução
    mlflow.log_param("test_size", test_size)
    mlflow.log_param("random_state", random_state)

    # Registrar os hiperparâmetros do modelo
    mlflow.log_param("n_estimators", n_estimators)
    mlflow.log_param("max_depth", max_depth)

    # Registrar as métricas calculadas
    mlflow.log_metric("accuracy", accuracy)
    mlflow.log_metric("f1_score", f1)

    # Registrar o modelo treinado
    mlflow.sklearn.log_model(
        modelo,
        name="model"
    )
```