

--	--	--

FACULDADE DE TECNOLOGIA

CAMPUS VOTORANTIM

CIÊNCIA DE DADOS PARA NEGÓCIOS

Ana Elisa Rubinato Cavalheiro
Arthur Nunes dos Santos
Bruno Felipe de Souza Araujo
Caio Cesar Corrá
Lucas Camelo
Nicole Fava
Pires

PROJETO INTEGRADOR VI : CHOPP & CIA

--	--	--

--	--	--

Ana Elisa Rubinato Cavalheiro
Arthur Nunes dos Santos
Bruno Felipe de Souza Araujo
Caio Cesar Corrá
Lucas Camelo
Nicole Fava
Pires

Relatório do Projeto Integrador do 6º semestre
apresentado à Faculdade de Tecnologia de
Votorantim como requisito parcial da disciplina do
curso Superior de Tecnologia em Ciência de
Dados.

Orientadora: Prof. Luis Claudio dos Santos

--	--	--

--	--	--

RESUMO

Refazer

O presente trabalho relata o desenvolvimento de um modelo preditivo baseado em *Machine Learning* para a Chopp & Cia, uma distribuidora de bebidas estrategicamente localizada na fronteira entre Ponta Porã (Brasil) e Pedro Juan Caballero (Paraguai). A empresa enfrenta um desafio operacional grave denominado "Risco Integrado" ou "Dupla Inadimplência". Este problema é caracterizado pela combinação do risco financeiro, referente ao atraso no pagamento das vendas, com o risco logístico, que consiste na retenção indevida de equipamentos cedidos em regime de comodato, como chopeiras e barris. O objetivo central do projeto foi desenvolver um classificador capaz de avaliar o perfil e o histórico do cliente no ato da compra, prevendo a probabilidade de este se tornar um risco crítico para a operação. A metodologia adotada incluiu a extração de dados do ERP da empresa, tratamento e isolamento das transações principais (*core business*), criação de variáveis comportamentais (como análise de *aging* e frequência) e uma ampla Análise Exploratória de Dados (EDA). Para a modelagem preditiva, foram treinados, validados e comparados três algoritmos de classificação binária: Regressão Logística, Árvore de Decisão e Floresta Aleatória (*Random Forest*). O modelo *Random Forest* apresentou uma superioridade preditiva acentuada, lidando de forma robusta com a heterogeneidade dos dados transfronteiriços e alcançando uma métrica de separação de perfis (AUC-ROC) de 97,6%. Conclui-se que a implementação da solução via API confere à gerência uma ferramenta de tomada de decisão automatizada e altamente confiável, com potencial projetado para reduzir os gargalos de fluxo de caixa e as perdas de ativos físicos em aproximadamente 35% ao ano.

PALAVRAS-CHAVE: Análise preditiva; Machine Learning; Random Forest; Gestão de risco.

--	--	--

--	--	--

ABSTRACT

This work reports the development of a predictive model based on Machine Learning for Chopp & Cia, a beverage distributor strategically located on the border between Ponta Porã (Brazil) and Pedro Juan Caballero (Paraguay). The company faces a severe operational challenge called "Integrated Risk" or "Double Default". This problem is characterized by the combination of financial risk, referring to delayed sales payments, and logistical risk, which consists of the improper retention of equipment provided under a free loan agreement (*comodato*), such as draft beer dispensers and kegs. The main objective of the project was to develop a classifier capable of evaluating the customer's profile and history at the time of purchase, predicting the probability of them becoming a critical risk to the operation. The methodology adopted included data extraction from the company's ERP, treatment and isolation of main transactions (*core business*), creation of behavioral variables (such as aging analysis and frequency), and an extensive Exploratory Data Analysis (EDA). For the predictive modeling, three binary classification algorithms were trained, validated, and compared: Logistic Regression, Decision Tree, and Random Forest. The Random Forest model showed marked predictive superiority, robustly handling the heterogeneity of cross-border data and achieving a profile separation metric (AUC-ROC) of 97.6%. It is concluded that the implementation of the solution via API provides management with an automated and highly reliable decision-making tool, with a projected potential to reduce cash flow bottlenecks and physical asset losses by approximately 35% per year.

KEY WORDS: Predictive analysis; Machine Learning; Random Forest; Risk Management.

--	--	--

--	--	--

LISTA DE FIGURAS

Figura 1 - Imagem aérea da front. Ponta Porã (Brasil) e Pedro Juan Caballero (Paraguai)	8
Figura 2 - mapa do traçado urb. munic. Ponta Porã (Brasil) e Pedro Juan Caballero (Paraguai).	10
Figura 3 - Quadro Kanban do Jira utilizado para a coordenação do projeto	18
Figura 4 - Resultados da Análise Exploratória de dados preliminar	21
Figura 5 - Dashboard do perfil 360 ° do cliente	24
Figura 6 - Resultados do Termômetros de Risco	26
Figura 7 - Histórico de total de faturamento x quantidade de pedidos	27
Figura 8 - Histórico de inadimplência financeira e de devolução de comodato	28
Figura 9 - Análise de Aging dos atrasos	29
Figura 10 - Radiografia de risco dos clientes	30
Figura 11 - Matriz de Confusão: Regressão Logística	33
Figura 12 - Matriz de Confusão: Árvore de decisão	35
Figura 13 - Matriz de Confusão: Floresta aleatória	36
Figura 14 - Curva ROC: Comparação entre os modelos	37
Figura 15 - Análise das importâncias das variáveis por modelo	38

--	--	--

--	--	--

LISTA DE TABELAS

Tabela 1 - Comparativo entre as abordagens selecionadas

--	--	--

--	--	--

SUMÁRIO

1 INTRODUÇÃO	8
1.1 Localização Geográfica	9
1.1.1 Perfil Populacional e Social	9
1.1.2 Indicadores Econômicos (PIB)	11
1.1.3 Movimentação Comercial na Fronteira	11
1.2 O Problema de Negócio	12
1.3 Objetivos do Projeto	13
1.3.1 Objetivos Específicos	13
2 REFERENCIAL TEÓRICO / FUNDAMENTAÇÃO	14
2.1 Regressão Logística (<i>Logistic Regression</i>)	14
2.2 Árvore de Decisão (<i>Decision Tree</i>)	15
2.3 Floresta Aleatória (<i>Random Forest</i>)	15
2.4 Comparativo de Estratégias e Impactos	16
2.5 Expectativa Prévia de Desempenho	16
3 METODOLOGIA	17
3.1 Extração	17
3.2 Engenharia de Atributos	19
3.2.1 Visão de Consumo e Engajamento (VW_CALCULO_SCORE_VENDAS)	19
3.2.2 Visão de Risco Logístico e Comodatos (VW_CALCULO_SCORE_COMODATO)	20
3.2.3 Visão de Performance Financeira (VW_CALCULO_SCORE_FINANCEIRO)	20
4 ANÁLISES E RESULTADOS	21
4.1 Análise Exploratória dos Dados (EDA)	23
4.1.1 Termômetro de Risco: Financeiro vs. Retenção de Equipamento	25
4.1.2 Análise Temporal das Vendas	27
4.1.3 Análise de Aging	28
4.1.4 Radiografia de Risco por Cliente	30
4.2 Modelagem Preditiva	32
4.3 Desempenho da Regressão Logística	33
4.4 Desempenho da Árvore de Decisão	34

--	--	--

--	--	--

4.5 Desempenho do Random Forest	36
4.6 Importância dos Atributos	38
4.7 Discussão dos Resultados	39
5 PLANEJAMENTO DE DEPLOY.....	40
6 CONCLUSÃO.....	41
6.1 Próximos Passos	41
6.2 Evolução Técnica.....	42
6.3 Sugestão de Melhorias e Dificuldades Encontradas	42

--	--	--

--	--	--

1 INTRODUÇÃO

A operação de fornecimento de equipamentos em regime de comodato, é uma prática comercial estratégica e amplamente adotada no setor de bebidas (SLACK; CHAMBERS; STUART, 2018). No entanto, ela traz consigo desafios significativos relacionados à alocação de ativos físicos. O presente projeto tem como objeto de estudo a análise de risco de vendas da Chopp & Cia, uma distribuidora de bebidas fundada em Março de 2024 e localizada estrategicamente na cidade de Ponta Porã (MS), na fronteira seca entre o Brasil e o Paraguai, conforme demonstrado pela figura abaixo:

Figura 1 - Imagem aérea da fronteira entre Ponta Porã (Brasil) e Pedro Juan Caballero (Paraguai)



Fonte: (BARBOSA; NOGUEIRA, 2024)

--	--	--

--	--	--

1.1 Localização Geográfica

A fronteira entre Brasil e Paraguai, especificamente no eixo formado pelas "cidades gêmeas" Ponta Porã (Mato Grosso do Sul) e Pedro Juan Caballero (Departamento de Amambay), constitui um dos cenários de maior integração transfronteiriça da América do Sul. Caracterizada pela "fronteira seca", onde apenas uma avenida (a Avenida Internacional) delimita a soberania nacional, a região funciona como um organismo econômico único, apresentando desafios e oportunidades singulares, principalmente para o setor de distribuição de bebidas e logística.

1.1.1 Perfil Populacional e Social

A conurbação internacional que integra os municípios de Ponta Porã (no estado de Mato Grosso do Sul, Brasil) e Pedro Juan Caballero (Paraguai) configura um mercado consumidor robusto e binacional, cuja população total excede a marca de 220 mil habitantes. Do lado brasileiro, conforme os dados consolidados do Censo 2022 realizado pelo Instituto Brasileiro de Geografia e Estatística (IBGE), Ponta Porã registra uma população de 92.017 pessoas. Este contingente apresenta uma trajetória de crescimento contínuo, sustentada principalmente pela pujança do agronegócio regional e pelo fortalecimento do polo de ensino superior, que atrai um fluxo constante de novos residentes e investimentos.


No território paraguaio, a dinâmica populacional é ainda mais acentuada. Segundo os resultados oficiais do Censo 2022, conduzido pelo *Instituto Nacional de Estadística* (INE), Pedro Juan Caballero abriga 127.437 habitantes, consolidando-se como a sétima maior cidade do Paraguai e o principal epicentro urbano do Departamento de Amambay. Sob a ótica do desenvolvimento social, Ponta Porã apresenta um Índice de Desenvolvimento Humano (IDH) de 0,701, patamar classificado como "Alto" pelas métricas internacionais. Em paralelo, o Paraguai registra um indicador nacional de 0,728, com o Departamento de Amambay destacando-se historicamente como um dos motores do desenvolvimento paraguaio. Essa relevância econômica é fundamentada na prestação de serviços e na consolidação de um expressivo polo educacional, notadamente voltado às faculdades de medicina, que exercem um impacto direto na circulação de renda e na demanda por bens de consumo na fronteira.

--	--	--

--	--	--

A distribuição urbana de ambas as cidades pode ser melhor observada pela figura 2 abaixo:

Figura 2 - mapa do traçado urbano dos municípios de Ponta Porã (Brasil) e Pedro Juan Caballero (Paraguai)



Fonte: LAMBERTI (2006).

--	--	--

--	--	--

1.1.2 Indicadores Econômicos (PIB)

O dinamismo econômico regional é impulsionado pela simbiose estratégica entre o vigor do agronegócio brasileiro e a capilaridade do comércio de importados paraguaios. No território brasileiro, o município de Ponta Porã apresentou um notório avanço em sua produção de riqueza, atingindo um Produto Interno Bruto (PIB) de R\$6,07 bilhões, conforme os indicadores consolidados de 2023 (reportados em 2025). Essa estrutura econômica fundamenta-se, primordialmente, na robustez do setor de serviços e na produtividade da agropecuária, que permanecem como os pilares de sustentação local.

Simultaneamente, Pedro Juan Caballero exerce um papel de centralidade absoluta no Departamento de Amambay. Na condição de capital e principal polo logístico, o distrito é responsável por aproximadamente 92% da receita de bens e serviços departamentais, o que confere à cidade um PIB estimado de US\$1,21 bilhão (aproximadamente R\$6,4 bilhões). Esse desempenho está alinhado à conjuntura macroeconômica do Paraguai, que manteve um crescimento estável próximo a 4,7% no biênio 2024/2025. Tal expansão é reflexo direto da intensidade das transações no comércio fronteiriço — que movimentou globalmente mais de US\$3,1 bilhões em 2025 — e da eficiência nas exportações de grãos, consolidando a região como um eixo comercial de alta relevância para o Mercosul.

1.1.3 Movimentação Comercial na Fronteira

O eixo fronteiriço Ponta Porã-Pedro Juan Caballero consolida-se como um referencial indispensável para a análise do fluxo comercial e do comportamento de consumo sul-americano. De acordo com relatórios recentes de entidades setoriais e do Banco Central do Paraguai (BCP), o comércio de fronteira no país movimentou cifras superiores a US\$3,1 bilhões em 2025, o que representa uma expansão de 11,3% em comparação ao exercício anterior. Nesse cenário, Pedro Juan Caballero consolida-se, ao lado de Ciudad del Este, como um dos principais centros de convergência de capitais e de turismo de compras da região.

--	--	--

--	--	--

Essa intensa dinâmica econômica é intrinsecamente vinculada à volatilidade cambial entre o Real (BRL), o Dólar Americano (USD) e o Guarani (PYG). Tal flutuação exerce influência direta na formação de custos e nos preços finais de bens de consumo, incluindo produtos de alta rotatividade como o chopp. Para o setor de distribuição, essa sensibilidade cambial é um fator crítico, pois impacta tanto o poder de compra do público local quanto a atratividade do produto frente ao fluxo turístico flutuante. Portanto, a compreensão dessas variáveis macroeconômicas é essencial para a gestão de riscos e para a sustentabilidade operacional de empreendimentos inseridos neste mercado transfronteiriço.

1.2 O Problema de Negócio

O modelo de negócio da distribuidora sustenta-se em um ecossistema duplo e interdependente: a venda recorrente de insumos (barris de chopp) e a operação logística de comodato, que consiste no empréstimo temporário de equipamentos indispensáveis para o consumo, como chopeiras e cilindros de gás. Esse modelo garante alta abrangência e fidelização, mas introduz complexidades rigorosas na gestão de fluxo de caixa e giro de ativos físicos. Devido à sua posição geográfica privilegiada, a empresa atende a um público diverso e transfronteiriço, englobando consumidores finais (Pessoas Físicas), estabelecimentos comerciais locais (Pessoas Jurídicas) e clientes estrangeiros (majoritariamente de Pedro Juan Caballero).

A principal dor da Chopp & Cia reside na gestão do chamado Risco Integrado ou Dupla Inadimplência. Por operar com a venda do produto atrelada ao empréstimo de um ativo de alto valor agregado, a empresa está exposta a duas frentes de vulnerabilidade que afetam diretamente a sua margem de lucro:

- Risco Financeiro (Crédito): Atrasos no pagamento das parcelas referentes à venda do chopp. Atualmente, cerca de 40% da carteira apresenta apenas esse tipo de fricção;
- Risco Logístico (Comodato): A retenção indevida e o atraso na devolução dos equipamentos emprestados, o que paralisa o giro de estoque da empresa e impede que o maquinário seja revertido em aluguel para outros clientes.

--	--	--

--	--	--

A identificação do problema ocorreu em situações em que o cliente final desejava realizar uma compra, porém não havia equipamento disponível para comodato. Isso gerava insatisfação e ocasionava a perda da venda devido ao atraso na devolução de pedidos anteriores. O gargalo tornou-se ainda mais severo ao observar a sazonalidade do negócio: os maiores índices de retenção de chopeiras e calotes financeiros ocorrem justamente nos meses de pico de vendas (setembro a dezembro). Durante a alta temporada, a operação logística foca exclusivamente na entrega, perdendo a tração nas réguas de cobrança e na logística reversa, resultando em um acúmulo perigoso de capital na rua e risco de perda patrimonial.

1.3 Objetivos do Projeto

Evoluir a solução preditiva desenvolvida no ciclo anterior para um ambiente analítico de produção escalável e governado, implementando uma arquitetura em Databricks/Lakehouse integrada a práticas de MLOps via MLflow. O projeto visa consolidar os dados transacionais de clientes, quantificar o impacto de decisões de negócio na modelagem (população, definição de alvo e vazamento de dados) e disponibilizar um modelo campeão auditável capaz de estimar o risco de inadimplência financeira e retenção indevida de comodato, automatizando a escoragem contínua da carteira para suporte à decisão comercial.

1.3.1 Objetivos Específicos

- **Consolidação e Limpeza dos Dados:** Refinar a extração do ERP corrigindo distorções no histórico de compras (separando vendas reais de comodato), tratando registros inativos e removendo dados nominais para evitar viés e vazamento de informação.
- **Implementação no Databricks:** Migrar a base para o ambiente Databricks/Delta Lake com Unity Catalog, garantindo tabelas organizadas, versionadas e prontas para análise.
- **Rastreabilidade com MLflow:** Utilizar o MLflow para registrar parâmetros, métricas de validação cruzada e o histórico de execuções de cada teste, além de gerenciar a versão do modelo promovido a produção.
- **Estudo e Comparação de Cenários:** Avaliar o impacto real de diferentes escolhas de negócio (recortes de clientes, réguas de atraso e conjuntos de variáveis), medindo o quanto o desempenho do modelo muda ao retirar variáveis derivadas do próprio atraso.
- **Modelagem e Avaliação Crítica:** Treinar e comparar modelos (Regressão Logística, Árvore

--	--	--

--	--	--

de Decisão e Random Forest) utilizando a métrica MCC (Coeficiente de Correlação de Matthews) para lidar com a base desbalanceada.

- Escoragem e Entrega do Pacote Final: Empacotar o modelo campeão e gerar a base de clientes classificada em faixas de risco (*Baixo, Médio e Alto*), permitindo o consumo direto por relatórios e réguas de cobrança.

--	--	--

--	--	--

2 REFERENCIAL TEÓRICO / FUNDAMENTAÇÃO

Para ajudar a Chopp & Cia a reduzir seus prejuízos operacionais, este projeto utilizou três algoritmos clássicos de Aprendizado de Máquina Supervisionado para classificação binária. O objetivo do modelo é identificar com antecedência o cliente de Alto Risco ($y = 1$) frente ao Bom Pagador ($y = 0$), considerando tanto o atraso financeiro em parcelas quanto a não devolução de chopeiras e barris emprestados em comodato. Diferente de cenários bancários tradicionais, a base da empresa tem cerca de 90% dos clientes classificados em risco pelo critério histórico de tolerância ($>20\%$ de atraso). Por isso, o desafio central não é apenas detectar o devedor, mas reconhecer com segurança os poucos bons pagadores para não travar vendas saudáveis. A escolha de múltiplos modelos permite equilibrar a capacidade de explicação com a precisão da resposta.

2.1 Regressão Logística (*Logistic Regression*)

A Regressão Logística é um modelo estatístico linear que calcula a probabilidade de um evento acontecer, comprimindo a saída sempre entre 0 e 1 (0% a 100% de probabilidade) através da função logística sigmóide.

Estratégia: O modelo aprende ajustando pesos para cada característica do cliente, como o intervalo entre pedidos, a frequência de compras e os termos combinados no empréstimo das chopeiras. Para que valores em dinheiro ou quantidades não distorcessem o cálculo por terem ordens de grandeza diferentes, colocamos todas as variáveis numéricas na mesma escala antes do treino. Também aplicamos regularização para controlar a complexidade do algoritmo, evitando que ele decore detalhes pontuais da base e perca a capacidade de generalizar para novos clientes. Além disso, como cerca de 90% da carteira histórica possui algum atraso, ativamos o balanceamento de classes para penalizar mais os erros cometidos contra os bons pagadores, garantindo que a minoria não fosse ignorada pelo modelo.

Impacto no Negócio: A maior vantagem desse algoritmo é a clareza para explicar seus resultados. Como os dados foram padronizados, o peso final atribuído a cada variável mostra diretamente sua influência na pontualidade: valores positivos indicam fatores que elevam a probabilidade de inadimplência, enquanto valores negativos apontam hábitos que protegem a distribuidora. Na

--	--	--

--	--	--

prática, isso permite que a empresa entenda o motivo por trás do risco calculado, embasando decisões comerciais seguras, como solicitar pagamento antecipado no Pix ou cobrar caução antes de entregar a chopeira.

--	--	--

--	--	--

2.2 Árvore de Decisão (Decision Tree)

A Árvore de Decisão é um modelo que organiza a tomada de decisão em um formato visual de galhos e folhas, dividindo a base de clientes por meio de regras diretas do tipo "se-então". Ela separa os clientes em grupos cada vez mais homogêneos de acordo com o histórico de compras e pagamentos.

Estratégia: O modelo avalia todas as características cadastradas e encontra o melhor ponto de corte para separar os clientes de risco dos bons pagadores, buscando a divisão mais limpa possível a cada etapa. Para evitar que o algoritmo decore a base de treino e falhe com novos pedidos, controlamos o tamanho máximo da estrutura e fixamos uma quantidade mínima de clientes por grupo final. Regras que isolavam menos de cinco clientes foram evitadas por representarem meras coincidências do histórico em vez de padrões reais de comportamento. Além disso, o modelo recebeu um ajuste de peso para tratar com o mesmo rigor a classe minoritária de bons pagadores.

Impacto no Negócio: Sua maior vantagem prática é a facilidade de leitura e auditoria das regras pela equipe da distribuidora. Diferente de fórmulas matemáticas fechadas, a árvore gera um mapa visual com o caminho percorrido pelo cliente (por exemplo: histórico recente curto somado a compras com prazo costuma antecipar a retenção de equipamentos). Isso permite criar políticas comerciais objetivas e automáticas, como orientar a retenção preventiva de chopeiras ou direcionar o fechamento de pedidos para modalidades à vista.

2.3 Floresta Aleatória (Random Forest)

A Floresta Aleatória evolui a ideia da árvore de decisão simples utilizando o aprendizado por conjunto (*ensemble*), que combina as previsões de dezenas ou centenas de árvores independentes para chegar a um resultado final muito mais seguro e imune a ruídos da base.

Estratégia: O modelo treina cada árvore com sorteios aleatórios de clientes da base histórica e limita as variáveis disponíveis em cada etapa de divisão. Com isso, as árvores olham para recortes ligeiramente diferentes e erram em direções distintas, fazendo com que a média ou votação do conjunto compense e anule as falhas individuais. Também aplicamos um limite de profundidade e o balanceamento de pesos para dar atenção proporcional aos clientes da classe de bons pagadores,

--	--	--

--	--	--

que são a minoria.

Impacto no Negócio: Essa abordagem resolve a instabilidade da árvore simples, evitando que o modelo decore o passado e erre ao avaliar novos pedidos de venda e comodato. Embora funcione como uma "caixa-preta" por não gerar um diagrama único para leitura direta, ela calcula a importância de cada variável ao longo de toda a floresta. Na prática, isso aponta à distribuidora quais hábitos de compra mais pesam no risco e gera uma probabilidade precisa para escorar toda a carteira em faixas (*Baixo, Médio e Alto* risco), orientando ações preventivas de crédito e logística.

--	--	--

--	--	--

2.4 Comparativo de Estratégias e Impactos

A escolha do algoritmo ideal exige o balanceamento entre a capacidade de detecção de padrões complexos e o custo computacional ou analítico. A Tabela 1 resume as principais distinções operacionais:

Tabela 1 - Comparativo entre as abordagens selecionadas

Modelo	Complexidade	Interpretabilidade	Resistência a Outliers	Escalonamento	Principal Vantagem no Negócio
Regressão Logística	Baixa	Alta	Sensível	Sim (StandardScaler)	Transparência no impacto marginal de cada indicador.
Árvore de Decisão	Média	Média	Robusta	Não	Geração de regras práticas auditáveis pela operação
Floresta Aleatória	Alta	Baixa	Muito Robusta	Não	Maior robustez e menor taxa de sobreajuste.

Fonte: autoria própria, 2026.

2.5 Expectativa Prévia de Desempenho

A hipótese direcional deste projeto é que o modelo de Floresta Aleatória (*Random Forest*) apresentará a superioridade preditiva mais acentuada. Em cenários de risco de crédito e retenção de ativos logísticos, as classes costumam ser desbalanceadas (a maioria dos clientes paga e devolve no prazo, gerando um volume menor de exemplos de inadimplência real).

Neste contexto, métricas tradicionais como a Acurácia global podem mascarar o real desempenho do modelo, pois em uma base onde cerca de 90% dos clientes têm histórico de atraso, qualquer chute ingênuo na classe majoritária acertaria 90% das vezes sem identificar os bons pagadores. Por essa razão, adotou-se o Coeficiente de Correlação de Matthews (MCC) como métrica norteadora, equilibrando a Precisão (para evitar o bloqueio injusto de bons clientes) e o Recall (para não deixar passar inadimplentes graves e perdas de chopeiras).

A expectativa de negócio é que a combinação em comitê (*Ensemble*) supere de forma clara o piso do modelo ingênuo (MCC = 0), comprovando que aprendeu padrões reais de comportamento em vez de

--	--	--

--	--	--

ruídos do histórico. A validação dessa hipótese fornecerá à distribuidora uma ferramenta confiável para classificar novos pedidos em faixas de risco (*Baixo, Médio e Alto*), automatizando a tomada de decisão comercial e direcionando ações preventivas — como exigência de pagamento à vista ou caução — nos casos de risco financeiro e logístico comprovadamente críticos.

--	--	--

--	--	--

3 METODOLOGIA

Os estudos realizados neste projeto foram inicialmente desenvolvidos em Python via Jupyter Notebook. A partir da extração de dados via SQL foi elaborada uma Análise Exploratória dos Dados para melhor entendimento do negócio e das variáveis presentes no banco que auxiliaram no desenvolvimento do modelo. Para evoluir a solução de um ambiente local (Jupyter Notebook) para uma arquitetura produtiva, escalável e de fácil governança, o pipeline de preparação, tratamento e modelagem foi totalmente transposto para o Databricks Workspace, com as seguintes bases:

- **Arquitetura Lakehouse:** Os scripts de ingestão e engenharia de atributos desenvolvidos anteriormente em Python/Pandas foram otimizados e migrados para o ambiente Databricks. As tabelas tratadas e as visões consolidadas (VW_CALCULO_SCORE_VENDAS, VW_CALCULO_SCORE_COMODATO e VW_CALCULO_SCORE_FINANCEIRO) passaram a ser persistidas no formato Delta Lake.
- **Modularização em Notebooks no Workspace:** O fluxo de trabalho foi organizado de forma modular no Workspace do Databricks, dividindo o pipeline em etapas bem definidas:
 - **Ingestão e Carga Incremental:** Leitura das tabelas brutas atualizadas e aplicação das travas de privacidade e LGPD.
 - **Engenharia de Atributos e Consolidação:** Execução das agregações para geração dos 15 atributos (ALL_FEATURES) no nível do cliente.
 - **Treinamento e Validação de Modelos:** Execução dos algoritmos em ambiente distribuído.
- **Integração com MLflow:** No Databricks Workspace, integrou-se o MLflow como gerenciador do ciclo de vida dos modelos de Machine Learning (MLOps), o qual será mais bem detalhado nos tópicos a seguir.

3.1 Extração

O desenvolvimento deste projeto baseou-se nos princípios da metodologia ágil, visando entregas iterativas e adaptáveis a cada etapa do processo analítico. Para a coordenação das atividades, utilizou-se o Planner da Microsoft como ferramenta central de gestão, o que permitiu a

--	--	--


--	--	--

estruturação do backlog, o planejamento de sprints e o rastreamento contínuo do progresso das tarefas. Essa organização facilitou o acompanhamento de todas as fases do ciclo de vida dos dados desde a extração e análise exploratória até o treinamento e validação dos modelos, garantindo transparência, colaboração eficiente e rápida capacidade de adaptação frente aos insights gerados em cada ciclo de experimentação.

--	--	--

--	--	--

Figura 3 - Quadro Kanban do Jira utilizado para a coordenação do projeto



Fonte: autoria própria, 2026

A fase de extração e ingestão dos dados foi reestruturada para atender às diretrizes do Manual do PI 6 e às exigências da Lei Geral de Proteção de Dados (LGPD - Lei nº 13.709/2018). A base de dados original foi extraída do ERP da distribuidora (DB_POWER_SYS - SQL Server) e atualizada com o histórico transacional recente, garantindo a temporalidade adequada para o treinamento do modelo preditivo, com base nos pontos abaixo:

- Anonimização e Minimização de Dados:
- Em vez de expor o ID_PESSOA / ID_CLIENTE sequencial bruto do ERP (que permite re-identificação indireta por cruzamento com a base de dados operacional), geramos um ID_CLIENTE_ANONIMO via hash SHA-256 com salt e eliminamos identificadores diretos como NM_PESSOA, DS_FANTASIA, CPF, CNPJ, EMAIL, TELEFONE, ENDERECO, INSCRICAO_ESTADUAL e descartamos os campos de texto livre.
- Tratamento de LGPD e Privacidade: A utilização dos dados limitou-se estritamente à finalidade de análise comportamental de crédito e gestão de risco logístico de comodato, amparada pela hipótese legal de proteção ao crédito (Art. 7º, X da LGPD). Dados categóricos de perfil foram agregados em níveis genéricos (TP_TIPO: Pessoa Física, Pessoa Jurídica e Estrangeiro) e localizações foram tratadas por municípios agrupados (CIDADE), prevenindo qualquer possibilidade de reidentificação ou inferência de dados sensíveis dos clientes.
- Atualização e Filtragem do Core Business: A base transacional foi atualizada e filtrada para remover ruídos cadastrais. Vendas de itens periféricos (ex: copos e descartáveis) foram desconsideradas através de expressões regulares (Regex) na tabela de produtos, mantendo no

--	--	--

--	--	--

escopo de extração exclusivamente o *core business* da empresa: CHOPP, CHOPEIRA, BARRIL e CILINDRO. Essa limpeza garantiu a atualização fidedigna das métricas de volume, ticket médio e comportamento de comodato.

--	--	--

--	--	--

3.2 Engenharia de Atributos

A etapa de Engenharia de Atributos teve como objetivo transformar os dados transacionais de vendas, financeiro, comodatos e cadastro em variáveis consolidadas no nível do cliente (ID_PESSOA). Essa abordagem permite representar o comportamento de cada cliente por meio de atributos de consumo, relacionamento, exposição financeira, utilização de comodatos e características cadastrais, formando a base utilizada posteriormente nos modelos de Machine Learning.

A construção dos atributos foi realizada separadamente para cada trilha de negócio antes da consolidação. Essa estratégia evita a multiplicação de registros causada pela combinação direta entre itens de venda, parcelas financeiras e bens de comodato, garantindo que cada cliente permaneça representado por uma única linha no dataset final.

Atributos de Consumo e Comportamento

A trilha de vendas foi utilizada para representar o relacionamento do cliente com a empresa e seu padrão de consumo. Para isso, foram consideradas somente as operações classificadas como venda, enquanto as devoluções foram tratadas separadamente e incorporadas ao cálculo do valor financeiro.

Entre os principais atributos gerados estão:

- **FREQUENCIA_COMPRAS:** quantidade de pedidos distintos realizados pelo cliente, utilizada para representar a frequência de compra.
- **TOTAL_ITENS:** quantidade de itens associados às compras.
- **QTD_TOTAL_VENDIDA:** quantidade total de produtos vendidos, considerando também o efeito das devoluções.
- **TOTAL_GASTO:** valor financeiro líquido das movimentações, considerando as devoluções de forma negativa.
- **TICKET_MEDIO:** valor médio gasto por pedido.
- **DIAS_DESDE_PRIMEIRA_COMPRA:** tempo decorrido desde a primeira compra até a

--	--	--

--	--	--

data de corte.

- **DIAS_DESDE_ULTIMA_COMPRA:** quantidade de dias desde a última compra.
- **PRODUTO_FAVORITO:** produto com maior quantidade consumida pelo cliente.

Essas variáveis permitem representar diferentes dimensões do comportamento de consumo, como **frequência, volume, valor e recência**, aproximando a análise da lógica de RFM.

Um cuidado importante adotado foi não considerar uma devolução como uma nova compra. Dessa forma, a frequência representa efetivamente o comportamento de compra, enquanto o impacto financeiro das devoluções permanece refletido no valor líquido.

Atributos Financeiros

A trilha financeira foi construída a partir das parcelas dos títulos a receber. Nesse caso, o nível original dos dados é a parcela, permitindo identificar a quantidade de compromissos financeiros e o comportamento de pagamento de cada cliente.

Foram criados atributos como:

- **TOTAL_PARCELAS:** quantidade total de parcelas associadas ao cliente.
- **PARCELAS_ATRASADAS:** quantidade de parcelas que apresentaram atraso.
- **TAXA_ATRASO_PAGAMENTO:** proporção de parcelas atrasadas em relação ao total de parcelas.
- **MEDIA_DIAS_ATRASO_PAG:** média dos dias de atraso.
- **MAX_DIAS_ATRASO_PAG:** maior atraso registrado.
- **VALOR_TOTAL_PARCELAS:** valor total das parcelas associadas ao cliente.

O cálculo de atraso considera tanto parcelas pagas após o vencimento quanto parcelas que permaneciam sem baixa após o vencimento na data de corte. Essa definição evita classificar como adimplente um cliente que simplesmente ainda não realizou o pagamento.

Para o modelo, entretanto, as variáveis que constituem diretamente o alvo, como

--	--	--

--	--	--

TAXA_ATRASO_PAGAMENTO e PARCELAS_ATRASADAS, foram retiradas das features. Já MEDIA_DIAS_ATRASO_PAG foi mantida como **vazamento parcial reconhecido**, decisão posteriormente avaliada no notebook 08.

Atributos de Comodato

A trilha de comodatos foi utilizada para representar a exposição do cliente aos equipamentos cedidos pela empresa e seu comportamento de devolução.

Foram geradas as seguintes variáveis:

- **TOTAL_COMODATOS:** quantidade de contratos de comodato.
- **COMODATOS_ATRASADOS:** quantidade de contratos que apresentaram atraso na devolução.
- **TAXA_ATRASO_COMODATO:** proporção de comodatos atrasados.
- **MEDIA_DIAS_ATRASO_COM:** média dos dias de atraso na devolução.
- **MAX_DIAS_ATRASO_COM:** maior atraso registrado.
- **QTD_EQUIPAMENTOS:** quantidade total de equipamentos vinculados.
- **PRAZO_MEDIO_COMODATO:** prazo médio dos contratos.
- **VALOR_MEDIO_COMODATO:** valor médio associado aos comodatos.

Um tratamento específico foi realizado para evitar que vários equipamentos pertencentes ao mesmo contrato fossem contabilizados como vários eventos de atraso. Assim, a quantidade de equipamentos é somada individualmente, enquanto o risco de atraso é calculado na granularidade do contrato de comodato.

Essa distinção é importante porque um comodato contendo três chopeiras, por exemplo, continua representando um contrato, e não três ocorrências independentes de atraso.

Atributos relacionados à Forma de Pagamento

Também foi incorporada a condição de pagamento contratada no momento da venda. A variável foi

--	--	--

--	--	--

construída a partir do tipo de condição de pagamento, diferenciando compras à vista e a prazo.

O principal atributo criado foi:

- **PCT_COMPRAS_A_PRAZO:** percentual das compras realizadas na modalidade a prazo.

Essa variável foi escolhida por representar uma característica do comportamento comercial do cliente no momento da contratação, sem utilizar o resultado posterior do pagamento. Dessa forma, ela pode contribuir para caracterizar o perfil do cliente sem incorporar diretamente a informação utilizada para definir o atraso financeiro.

Atributos Cadastrais e de Perfil

Além dos atributos transacionais, foram utilizadas algumas características cadastrais para representar o perfil do cliente:

- **PERFIL:** classificação do tipo de pessoa.
- **CIDADE:** cidade agrupada e padronizada.
- **PAGAMENTO:** forma de pagamento cadastrada.

O atributo SEGMENTO foi analisado durante a EDA, mas não foi incluído no conjunto final de features, devido à qualidade e ao nível de ruído observado nos dados cadastrais.

Conjunto final de Features

Após a etapa de consolidação, o notebook 04 definiu **15 atributos para o treinamento dos modelos**, sendo **12 numéricos e 3 categóricos**.

Variáveis numéricas:

Feature	Representação
FREQUENCIA_COMPRAS	Frequência de compras
TICKET_MEDIO	Valor médio por compra

--	--	--

--	--	--

TOTAL_GASTO	Gasto total líquido
DIAS_DESDE_PRIMEIRA_COMPRA	Tempo de relacionamento
DIAS_DESDE_ULTIMA_COMPRA	Recência da compra
TOTAL_PARCELAS	Quantidade de parcelas
TOTAL_COMODATOS	Quantidade de comodatos
PCT_COMPRAS_A_PRAZO	Percentual de compras a prazo
PRAZO_MEDIO_COMODATO	Prazo médio dos comodatos
VALOR_MEDIO_COMODATO	Valor médio dos comodatos
MEDIA_DIAS_ATRASO_PAG	Média de atraso financeiro
MEDIA_DIAS_ATRASO_COM	Média de atraso de comodato

Fonte: Autoria propria 2026

Variáveis categóricas:

Feature	Representação
PERFIL	Perfil cadastral
CIDADE	Localização agrupada
PAGAMENTO	Forma de pagamento

Fonte: Autoria propria 2026

Essas 15 variáveis formam o conjunto ALL_FEATURES, utilizado como entrada dos modelos de Machine Learning.

Tratamento de valores ausentes e governança

Durante a preparação dos dados, os valores ausentes foram tratados de acordo com o significado de cada atributo. Variáveis de contagem, como parcelas, compras e comodatos, receberam valor zero quando o cliente não possuía registros naquela trilha. Já atributos como PRAZO_MEDIO_COMODATO e VALOR_MEDIO_COMODATO permaneceram nulos quando não existia comodato, pois a ausência do contrato não significa que seu prazo ou valor seja igual a

--	--	--

--	--	--

zero.

Para TICKET_MEDIO, os valores ausentes foram tratados separadamente, evitando interpretar a ausência de compra como uma compra de valor zero.

Também foram aplicadas regras de governança para impedir:

- utilização de identificadores pessoais como variáveis preditoras;
- utilização das próprias variáveis que compõem o alvo;
- utilização de variáveis que representam diretamente o resultado do risco;
- inclusão de informações que poderiam causar vazamento do alvo.

O alvo ALTO_RISCO é construído a partir das taxas de atraso financeiro e de comodato. Portanto, variáveis como TAXA_ATRASO_PAGAMENTO, TAXA_ATRASO_COMODATO, PARCELAS_ATRASADAS, COMODATOS_ATRASADOS, RISCO_FINANCEIRO, RISCO_COMODATO e AGING_* não são utilizadas como entrada dos modelos.

Por outro lado, MEDIA_DIAS_ATRASO_PAG e MEDIA_DIAS_ATRASO_COM foram mantidas conscientemente como vazamento parcial, uma vez que possuem origem aritmética relacionada ao alvo. Essa limitação foi registrada e posteriormente avaliada no notebook de cenários, permitindo medir o impacto dessas variáveis sobre o desempenho dos modelos.

--	--	--

--	--	--

Ambiente de desenvolvimento e práticas de MLOps

Para a execução do projeto, foi adotada uma estrutura de processamento dividida em notebooks, organizando o fluxo de dados desde a extração do banco operacional até a avaliação dos modelos de Machine Learning. O processo foi estruturado em etapas de extração, ingestão, análise exploratória, preparação dos dados, engenharia de atributos e construção e avaliação dos cenários de modelagem.

O Databricks foi utilizado como ambiente para publicação e processamento dos dados e para a execução das etapas relacionadas à modelagem. O dataset consolidado produzido na etapa de extração é disponibilizado no ambiente e utilizado pelos notebooks subsequentes. Quando executado no Databricks, o pipeline também permite a publicação dos resultados em tabelas no formato Delta, facilitando o armazenamento e o consumo dos resultados.

No desenvolvimento dos cenários de Machine Learning, foi utilizado o MLflow, integrado ao Databricks, para o acompanhamento dos experimentos. A estrutura adotada organiza cada combinação de população e definição do alvo como um experimento, enquanto diferentes conjuntos de atributos e algoritmos são registrados como execuções (*runs*) dentro desses experimentos.

Durante cada execução, são registrados parâmetros relacionados aos hiperparâmetros dos modelos, quantidade de atributos, configurações da validação cruzada e *random state*. Também são armazenadas métricas de avaliação, informações sobre a população analisada, prevalência da classe de risco e características do conjunto de atributos utilizado. Essa organização permite rastrear as diferentes configurações testadas e reproduzir os experimentos realizados.

O notebook de cenários também utiliza o MLflow para registrar o modelo definido para produção, juntamente com informações sobre o cenário utilizado, algoritmo, hiperparâmetros, atributos selecionados, versão dos dados e métricas obtidas na validação cruzada e no conjunto de teste. O modelo treinado é posteriormente armazenado como artefato, acompanhado de uma *model card* contendo informações sobre sua configuração e origem.

Nesse contexto, foram aplicadas práticas relacionadas a **MLOps**, principalmente no que se refere à

--	--	--

--	--	--

organização, rastreabilidade e reprodutibilidade dos experimentos. A metodologia mantém a separação entre preparação dos dados, treinamento, avaliação e geração do pacote de produção, permitindo acompanhar a evolução dos modelos e identificar quais configurações foram utilizadas em cada experimento.

O fluxo metodológico relacionado ao ambiente e ao Machine Learning pode ser representado da seguinte forma:

Extração → Ingestão → Databricks → EDA → Preparação → Engenharia de Atributos → Construção dos Cenários → Treinamento e Validação → MLflow → Avaliação → Pacote de Produção

A utilização desses recursos possibilita que o projeto não se limite à construção de um modelo preditivo, mas contemple também aspectos relacionados à organização do ciclo de vida do modelo, rastreabilidade dos experimentos e preparação dos artefatos para utilização posterior.

--	--	--

4 ANÁLISES E RESULTADOS **REFAZER**

O trabalho realizado no projeto integrador 5, PI V, trouxe a base da análise exploratória dos dados que guiaram o grupo sobre o entendimento das principais variáveis de negócio que poderiam auxiliar com a elaboração do modelo de Aprendizado de Máquina e que foi utilizada neste novo projeto integrador. A seguir mostraremos o fluxo das análises realizadas no projeto passado e como conseguimos reaproveitar considerando a atualização do bando de dados de um semestre para o outro ocm informações mais recentes.

Após a construção das três visões analíticas principais, vendas, comodatos e performance financeira, foi realizada uma Análise Exploratória de Dados (Exploratory Data Analysis – EDA), permitindo identificar padrões ocultos, tendências sazonais, correlações relevantes e comportamentos de risco presentes na base histórica da distribuidora. A análise exploratória foi fundamental para orientar a engenharia de atributos e apoiar a seleção das variáveis utilizadas nos modelos supervisionados.

A fase inicial de Análise Exploratória de Dados (EDA) concentrou-se no ranqueamento dos principais clientes por volume de transações, conforme demonstrado na figura XX abaixo, o que permitiu uma auditoria imediata sobre a integridade da base. Esta etapa permitiu identificar anomalias que, se não tratadas, comprometeriam a acurácia dos modelos de *Machine Learning* ao introduzir padrões de consumo enviesados ou informações categóricas ruidosas.

Figura 4 - Resultados da Análise Exploratória de dados preliminar

Top 10 Clientes por Volume de Compras		
Nome do Cliente	Segmento	Produto Mais Comprado
JET CHICKEN	RESTAURANTES,CHURRASCARIAS,PIZZARIAS,CAF	CHOPP BURGUESA 30 LTS
CASINO AMANBAY	CONSUMIDOR FINAL	CHOPP BURGUESA 50 LTS
VILA MADALENA	BARES E LANCHONETES	CHOPP BURGUESA 50 LTS
LARISSA TAMARA LOPES (DON CORLEONE)	CONSUMIDOR FINAL	CHOPP BURGUESA 50 LTS
LA BRASILENA	CONSUMIDOR FINAL	CHOPP BURGUESA 50 LTS
ALEMAO DISTRIBUIDORA E CONVENIENCIA EIRELI	CONSUMIDOR FINAL	COPO DESCARTAVEL 440 ML
FELIP'S BURGER LTDA	BARES E LANCHONETES	CHOPP BURGUESA 30 LTS
OILSON BOLICHE DUBAI	CONSUMIDOR FINAL	CHOPP BURGUESA 50 LTS
CASA AMARELA	CONSUMIDOR FINAL	CHOPP BURGUESA 50 LTS
JORGE MULLER	CONSUMIDOR FINAL	CHOPP BURGUESA 50 LTS

Fonte: Autoria própria, 2026.

--	--	--

A partir da visualização dos dez maiores clientes, observou-se uma desconexão crítica entre a natureza real do estabelecimento e sua classificação no sistema. Ao cruzar o nome fantasia (DS_FANTASIA) com o segmento registrado (DS_TIPO_ESTABELECIMENTO) identificaram-se casos em que grandes operações comerciais — como cassinos e restaurantes de alto volume — figuravam erroneamente sob o rótulo de "Consumidor Final". Para o modelo preditivo, tal imprecisão é prejudicial, uma vez que o comportamento de compra de um estabelecimento

comercial (pessoa jurídica) difere drasticamente de um perfil de um usuário final. Com isso foi usado apenas a classificação do tipo de cliente (TP_TIPO) que traz uma divisão mais simplista dos clientes entre Pessoas Físicas, Pessoa Jurídica e Estrangeiros. Esse problema de alimentação do banco de dados da distribuidora fez com que não fosse possível classificar clientes estrangeiros entre usuários e empresas.

Além das falhas cadastrais, a análise revelou um "ruído" no mix de produtos comercializados. Notou-se que itens de baixo valor agregado e periféricos ao negócio principal, como copos descartáveis, apareciam com destaque no ranking de consumo de grandes clientes. Uma vez que o escopo deste estudo é a previsão de inadimplência atrelada especificamente ao ciclo de consumo de Chopp e ao risco de perda de ativos em Chopeiras, a manutenção desses itens periféricos nas tabelas de treino geraria distorções no ticket médio e na frequência de recompra, camuflando o real comportamento do *core business*.

Diante das evidências expostas, o projeto avançou para um refinamento da base transacional. O objetivo foi isolar o ecossistema de produtos que sustenta o faturamento e o risco de comodato da distribuidora. Para tal, implementou-se uma filtragem via expressões regulares (*Regex*) na tabela TB_PRODUTO, isolando exclusivamente termos como “CHOPP, CHOPEIRA, BARRIL e CILINDRO”. Itens não relacionados, como gelo, água e descartáveis, foram expurgados das bases de vendas e comodato no nível de item, assegurando que o algoritmo aprenda padrões exclusivamente sobre os produtos de interesse.

No que tange à dimensão financeira, adotou-se uma abordagem metodológica distinta para preservar a integridade do valor dos pedidos. Ao contrário da filtragem por item, a base financeira foi tratada no nível de pedido: foram mantidas apenas as parcelas e notas fiscais de vendas que continham, no mínimo, uma unidade de chopp ou equipamento de comodato. Esta decisão justifica-se pelo fato de que o risco de crédito é inerente ao valor total da nota fiscal; embora um pedido possa conter itens secundários, é a presença dos produtos de alto valor agregado que define a natureza do perfil de risco do cliente e a viabilidade da transação para a distribuidora. Com este tratamento, eliminou-se o ruído estatístico, direcionando o treinamento dos modelos para os dados que efetivamente impactam a saúde financeira da operação.

--	--	--

--	--	--

4.1 Análise Exploratória dos Dados (EDA)


A primeira etapa consistiu na consolidação e tratamento dos dados extraídos do ERP da empresa. Após a higienização das tabelas e remoção de inconsistências, foram estruturadas análises estatísticas e visuais com apoio das bibliotecas Pandas, Matplotlib e Seaborn no ambiente Jupyter Notebook.

Durante o processo exploratório, observou-se que a base possuía forte heterogeneidade comportamental, principalmente devido ao contexto transfronteiriço da empresa, envolvendo diferentes perfis de consumidores, moedas e modalidades de pagamento.

Com o objetivo de compreender melhor o comportamento comercial e financeiro da base histórica, foi desenvolvido um dashboard analítico consolidando indicadores de pedidos, faturamento e ticket médio segmentados por perfil de cliente, localização e forma de pagamento, observado na figura abaixo.

--	--	--

Figura 5 - Dashboard do perfil 360 ° do cliente



Fonte: Autoria própria

Com base na consolidação do Dashboard 360° e no tratamento dos dados de georreferenciamento, a análise exploratória permitiu a extração de insights estratégicos que fundamentam a inteligência de negócio da distribuidora. Observou-se uma dualidade na estrutura de faturamento: enquanto o volume absoluto de pedidos é liderado por Pessoas Físicas, a sustentabilidade financeira e os maiores tickets médios provêm de Pessoas Jurídicas e clientes estrangeiros, reforçando a importância econômica da operação transfronteiriça. Geograficamente, Ponta Porã consolida-se como o núcleo operacional, apresentando uma correlação direta entre o perfil de cliente estrangeiro e a localidade de Pedro Juan Caballero. Em contrapartida, o volume de vendas em municípios periféricos sinaliza a necessidade de um planejamento logístico rigoroso, especificamente voltado ao recolhimento de ativos em comodato.

--	--	--

Sobre o comportamento de pagamento, a predominância de transações via dinheiro em espécie e arranjos de pagamentos instantâneos (Pix) assegura um fluxo de caixa ágil, enquanto as modalidades de crédito permanecem sendo preferencialmente escolhidas no segmento B2B e ao mercado internacional, que absorvem os pedidos de maior valor agregado. Do ponto de vista metodológico, o tratamento da variável de localização foi determinante, atingindo um índice de preenchimento de 97,7%.


4.1.1 Termômetro de Risco: Financeiro vs. Retenção de Equipamento

Para aprofundar a compreensão sobre os clientes inadimplentes, foi estruturada uma visualização comparativa específica, o Termômetro de Risco, que cruza a taxa de atraso financeiro com a taxa de atraso na devolução de comodatos em três dimensões distintas: Perfil, Localização e Forma de Pagamento, apresentadas na figura XX abaixo:

--	--	--

Figura 6 - Resultados do Termômetros de Risco

Termômetro de Risco: Financeiro vs. Retenção de Equipamento



Fonte: Autoria própria

A interpretação desta análise revelou insights vitais para a operação como Taxa de Atraso por Perfil que em todos os perfís, o atraso logístico (retenção de maquinário) é sempre superior ao atraso financeiro. A classe de "Estrangeiro" apresentou a menor taxa de atraso financeiro (47.4%), porém um alto índice de retenção de ativos (68.3%). Pessoas Físicas lideram a indisciplina com as chopeiras, superando 70% de taxa de retenção.

--	--	--

Já sobre Taxa de Atraso por Localização Geográfica, observa-se que a região de Amambai (Paraguai) apresenta um gargalo operacional extremo, com 100% de taxa de atraso em comodato, apesar de registrar a menor inadimplência financeira (14.3%), considera-se que os poucos registros observados para essas variáveis podem influenciar está assertividade de 100%. Já os clientes sem localização preenchida representam um risco cego focado nas finanças (60% de atraso).


Por fim, sobre a Taxa de Atraso por Forma de Pagamento, confirma-se a periculosidade do pagamento "A Prazo (Nota Assinada)" e "Cartão de Crédito", que disparam os gatilhos de inadimplência (76.3% e 100% no comodato, respectivamente). Em contrapartida, os clientes que optam pelo pagamento via PIX, embora ainda atrasem equipamentos, demonstram o melhor comportamento para o fluxo de caixa, com a menor taxa de atraso financeiro (41.8%).

4.1.2 Análise Temporal das Vendas

A análise temporal das vendas já foi realizada com o corte de dados utilizado para o projeto integrador VI e consolidou a forte sazonalidade operacional do negócio. Os gráficos de série temporal desenvolvidos no notebook mostraram crescimento expressivo do volume de pedidos entre os meses de setembro e dezembro, período relacionado a festas de final de ano, confraternizações, eventos corporativos, e ao aumento do turismo de fronteira. Esse comportamentos pode ser melhor observado pela análise apresentada pela figura 7.

--	--	--

Figura 7 - Histórico de total de faturamento x quantidade de pedidos & Histórico de inadimplência financeira e de devolução de comodato



Fonte: Autoria própria

--	--	--

O crescimento da demanda coincidiu com aumento relevante: dos atrasos financeiros, da retenção de comodatos, do número de clientes inadimplentes e do acúmulo de equipamentos em logística reversa conforme demonstrado pelo gráfico debaixo.


Esse comportamento confirmou um dos principais problemas identificados pela empresa de que durante períodos de alta temporada, a equipe operacional concentra esforços na entrega de novos pedidos, reduzindo a eficiência da cobrança financeira e recolhimento de equipamento.

4.1.3 Análise de Aging

No âmbito da modelagem de risco, a análise qualitativa da inadimplência exige a compreensão da gravidade temporal do atraso, indo além da simples identificação do devedor. Para aprofundar essa percepção, foi estruturada uma análise de aging (tempo de atraso), que mensura o tempo exato, em dias, de cada ocorrência e os agrupa em faixas de tolerância que variam de leve (1 a 7 dias) e médio (8 a 20 dias) até o nível crítico (acima de 21 dias). Essa distinção é fundamental para a gestão operacional, uma vez que um atraso de curto prazo na devolução de uma chopeira representa apenas um gargalo logístico momentâneo, enquanto períodos superiores a 30 dias sinalizam um risco iminente de perda definitiva do ativo.

--	--	--

Para garantir uma leitura precisa desse comportamento observado na figura XX, aplicou-se a Escala Logarítmica Simétrica (SymLog) na visualização dos dados, com a finalidade de mitigar o efeito de "cauda longa" e impedir que o volume massivo de atrasos de curto prazo ocultasse visualmente as ocorrências críticas de alto risco. A interpretação desse panorama revelou que a vasta maioria das pendências, tanto financeiras quanto de ativos, é solucionada em uma janela de até 15 dias. Esse padrão sugere que a inadimplência predominante na região fronteira não decorre necessariamente de má-fé, mas sim de fatores operacionais, como desorganização administrativa ou fluxos logísticos intrínsecos ao processo.




Fonte: Autoria própria

Contudo, observa-se que, embora o volume de ocorrências sofra uma redução acentuada após o 15º dia, o contingente de pedidos que ultrapassa a barreira dos 30 dias permanece em níveis preocupantes para o fluxo de caixa da distribuidora. Enquanto os atrasos de curto prazo acompanham a proporcionalidade natural da base de clientes, as faixas que compreendem de 21 a mais de 30 dias revelam desvios comportamentais atípicos. Esses dados indicam que, a partir desse estágio crítico, o perfil do cliente se altera significativamente, exigindo que o modelo de *Machine Learning* priorize essas variáveis para diferenciar o atraso rotineiro da inadimplência severa, protegendo assim o patrimônio e a sustentabilidade financeira do negócio.

--	--	--

4.1.4 Radiografia de Risco por Cliente


Esta nova etapa do projeto a análise exploratória focou em analisar o impacto das variáveis de negócio utilizadas para validar a melhor configuração para um modelo que melhor performasse. Na figura a seguir um resumo do detalhamento dos clientes com a base atualizada até Agosto de 2026.



Previamente à avaliação do risco de crédito, faz-se necessária a quantificação e a estratificação da base de clientes, delimitando a proporção daqueles que possuem histórico transacional efetivo. Cumpre notar que nem todo cliente cadastrado realizou operações de compra ou formalizou contratos de comodato de equipamentos. Sob a perspectiva da análise financeira, a ausência de registros históricos não deve ser equivocadamente interpretada como indicador de baixo risco, mas sim como uma situação de assimetria informacional, na qual a falta de dados impede a mensuração precisa da capacidade de pagamento. A concessão responsável de crédito exige distinguir com clareza os tomadores consolidados daqueles sobre os quais há incerteza cadastral, conforme ilustra o gráfico a seguir.

--	--	--

--	--	--



Como pode ser observado no gráfico, a grande maioria dos clientes se concentra no grupo de Risco Duplo (86%). Esse perfil representa o ponto mais crítico da análise, pois reúne clientes que possuem compromissos financeiros a prazo e, ao mesmo tempo, mantêm equipamentos da empresa sob comodato. Por concentrar a maior exposição financeira e patrimonial do negócio, esse grupo deve ser a prioridade máxima nas estratégias de monitoramento de crédito e negociação.

Por outro lado, os clientes inativos (4%) exigem cuidado por um motivo diferente: a falta de histórico. Em uma análise de risco, um cliente sem registros anteriores não pode ser classificado como de baixo risco, mas sim como um perfil desconhecido. Na prática, aprovar crédito para esse grupo sem dados prévios equivale a tomar uma decisão no escuro, e por isso foram retirados para elaboração do modelo.


Até esta etapa da pesquisa, as inadimplências financeiras e os atrasos logísticos foram analisados de forma isolada. Contudo, a vulnerabilidade operacional e o risco real associados aos contratos de comodato manifestam-se na convergência dessas duas dimensões. Diante disso, esta etapa metodológica realiza um cruzamento matricial definitivo, estabelecendo um diagnóstico

--	--	--

integrado do comportamento dos ativos sob a perspectiva individualizada de cada cliente (ID_CLIENTE).

O objetivo da abordagem apresentada na figura XX abaixo é segmentar a carteira de clientes em quatro quadrantes de fricção operacional, distinguindo os parceiros comerciais sustentáveis daqueles classificados como detratores críticos, os quais impõem prejuízo duplo à eficiência da organização.

Figura 10 - Radiografia de risco dos clientes



Fonte: Autoria própria

--	--	--

A transição da unidade de análise do nível de transação para a perspectiva individualizada do cliente revelou-se fundamental para mapear com precisão o perfil de risco real da carteira ativa. O cruzamento matricial das dimensões de inadimplência evidenciou um panorama que demanda intervenção gerencial estratégica, uma vez que apenas uma minoria de 20% da base de clientes enquadra-se na categoria de risco nulo, caracterizada pela estrita conformidade financeira e logística. O fato de a vasta maioria da carteira (78%) apresentar algum histórico de desconformidade sugere que os atrasos constituem um comportamento recorrente e sistêmico na operação analisada, deixando de ser eventos isolados.

Dentro desse ecossistema de fricções operacionais, o cenário de maior prevalência é o risco financeiro isolado, que afeta 40% da base. Este segmento é composto por clientes que apresentam pontualidade reduzida nos fluxos de liquidação, contudo, sem gerar passivos na retenção de bens de capital. Embora representem um canal ativo de giro de produtos, demandam fluxos mais ágeis e automatizados de cobrança. Em contrapartida, observa-se uma incongruência comportamental em 15% da carteira, caracterizada por clientes que cumprem rigorosamente os prazos de pagamento, mas descumprem os prazos de devolução dos ativos em comodato. Para este grupo específico, o fator restritivo não está associado à capacidade de crédito, mas sim a gargalos na eficiência da logística reversa e no monitoramento de ativos físicos.

O cenário mais alarmante, contudo, concentra-se na zona de risco crítico, que abrange expressivos 22% da base de clientes. Este grupo atua como um ofensor duplo, comprometendo simultaneamente o fluxo de caixa por meio do inadimplemento financeiro e imobilizando o patrimônio da organização, o que impede a realocação produtiva dos equipamentos e corrói as margens de lucro operacionais. Como diretriz mitigatória, este quadrante exige políticas severas de concessão, com restrições que incluem a obrigatoriedade de adiantamento integral e a instituição de depósitos de garantia para a liberação de novos ativos.

Diante desse panorama, o papel fundamental do modelo preditivo desenvolvido reside em sua capacidade de atuar como um mecanismo de detecção precoce de anomalias comportamentais. O objetivo central do algoritmo de Machine Learning será analisar as variáveis de entrada de novas propostas comerciais — tais como dados demográficos, localização geográfica, histórico

--	--	--

--	--	--

retrospectivo e modalidades de pagamento — a fim de estimar a probabilidade de um novo entrante


--	--	--

convergir para o estrato de risco crítico. Essa capacidade preditiva visa subsidiar a governança corporativa, permitindo a restrição preventiva ou a renegociação de termos contratuais antes da materialização do dano financeiro e patrimonial.

4.1.5 Impacto das Variáveis de Negócio

Para compreender a construção da base de dados utilizada no modelo, é fundamental mapear a trajetória dos clientes desde o sistema ERP até o conjunto final de análise. O objetivo dessa etapa é tornar transparente o impacto das escolhas do pipeline, respondendo a uma questão central: quantos clientes são descartados ao longo do fluxo e por quais motivos? Os dados passam primeiro pelas validações técnicas do sistema — como a filtragem de cadastros ativos e tipos de operação — e, em seguida, por critérios analíticos de negócio, como o consumo de produtos específicos e a exigência de um histórico transacional mínimo. Representar esse processo na forma de um funil garante que cada regra de exclusão fique clara e auditável, permitindo entender o efeito de cada decisão sobre o tamanho da amostra final, conforme apresentado no gráfico a seguir.

Fig XX: Impacto do filtro de qualidade das venda spara considerar cliente no modelo




A análise do funil evidencia que a filtragem inicial descarta 148 cadastros sem qualquer registro de compra. Na sequência, a aplicação do critério de negócio focado no segmento de chopp resulta na remoção de apenas 2 clientes dentre os 1.281 compradores remanescentes. Isso demonstra que esse recorte tem um custo amostral insignificante, uma vez que a carteira analisada já é naturalmente composta por compradores dessa categoria.

Em contrapartida, a exigência de um histórico transacional mínimo mostrou-se a etapa mais restritiva do fluxo. Ao impor o critério de pelo menos 3 compras, a base sofre uma redução drástica, caindo para 332 clientes. Esse gargalo ilustra o forte impacto que regras rigorosas de elegibilidade causam no tamanho da amostra para o modelo, ponto cujos impactos e inviabilidade serão aprofundados a seguir.

A definição do critério de inadimplência exige estabelecer um limiar que diferencie flutuações operacionais de caixa de um risco efetivo de não pagamento. Pequenos atrasos são comuns e frequentemente decorrem de fatores administrativos cotidianos, como feriados bancários ou rotinas de fechamento. Definir uma régua excessivamente sensível gera falsos alertas ao tratar esses ruídos temporários como inadimplência; por outro lado, uma régua permissiva demais só identifica o problema quando a recuperação do crédito já se torna inviável.

Para embasar essa decisão, o gráfico a seguir mapeia a variação do limiar de tolerância entre 10% e 50% de compromissos em atraso, demonstrando a proporção da carteira enquadrada em cada nível. Como a fixação dessa régua não é uma definição puramente estatística, mas sim uma escolha estratégica de negócio, a análise evidencia os impactos e trade-offs associados a cada opção de corte.

Fig. XX - Impacto do filtro do percentual de tolerância de atraso no modelo



A análise dos resultados revela um cenário de atraso crônico na carteira: mesmo ao flexibilizar a régua de tolerância para 50%, a maioria dos clientes continua sendo classificada na categoria de risco sob a lógica "OU". A definição da regra de combinação reflete um trade-off direto entre a proteção do negócio e a viabilidade técnica do modelo de aprendizado de máquina.

Ao utilizar o combinador "OU", o cliente é classificado como risco se atrasar a obrigação financeira ou a devolução do equipamento. Essa abordagem oferece proteção máxima aos dois ativos da empresa, mas reduz drasticamente a proporção de "bons pagadores", gerando um desbalanceamento de classes que prejudica o treinamento do modelo. Em contrapartida, a lógica "E" exige descumprimento simultâneo de

--	--	--


ambos os lados, garantindo amostras mais equilibradas para a modelagem, porém assumindo o risco de tratar como bom pagador o cliente que está inadimplente em apenas uma das frentes.

A mensuração do comportamento de pagamento por meio de taxas de atraso levanta uma questão metodológica fundamental: a partir de quantas transações essa métrica passa a refletir conduta habitual em vez de mero acaso? Por se tratar de uma razão direta, denominadores reduzidos geram forte discretização dos resultados. Com apenas uma compra, a taxa é obrigatoriamente 0% ou 100%; com duas, limita-se a intervalos de 50%. Nesses cenários, um cliente com uma única transação em atraso atinge 100% de inadimplência — um valor matematicamente correto, mas analiticamente irrelevante por ausência de histórico de reincidência. Apenas a partir de um volume maior de operações a granularidade dos dados se torna suficiente para diferenciar um imprevisto pontual de um padrão comportamental.

Essa restrição impõe um dilema prático ao projeto. Exigir um histórico mais denso torna a métrica de risco estatisticamente confiável, porém encolhe o tamanho da amostragem; por outro lado, aceitar todos os clientes preserva o volume da base, mas introduz ruído nos dados. A tabela a seguir mensura esse trade-off, explicitando o impacto direto do critério de corte sobre a volumetria da carteira.

Fig. XX: Impacto do filtro por quantidade de vendas

--	--	--



A análise dos resultados indica que a variável FREQUENCIA_COMPRAS contabiliza exclusivamente as vendas de chopp, sem registrar as movimentações de comodato, o que explica a baixa mediana de transações observada na carteira. Diante dessa característica, a imposição de um filtro de histórico de pelo menos três compras reduz a base a um ponto crítico: a classe de risco passa a contar com apenas 6 ocorrências reais (uma média de aproximadamente 1,2 caso por fold na validação cruzada), o que inviabiliza o treinamento e a validação de qualquer algoritmo preditivo.


Diante desse cenário, adotou-se a premissa de não filtrar a base por histórico mínimo (MIN_COMPRAS = 0). Essa escolha metodológica não pressupõe a eliminação do ruído gerado por poucas compras, mas reconhece que o custo amostral de descartar a maior parte da carteira é superior ao risco de aceitar a volatilidade das taxas. Para fundamentar essa decisão com dados concretos em vez de suposições, os impactos de ambos os cenários são comparados e mensurados empiricamente nas etapas seguintes da pesquisa.

Uma vez definida a manutenção de toda a base de clientes para preservar a amostragem, tornou-se fundamental identificar variáveis capazes de sinalizar o risco sem sofrer com o ruído estatístico de históricos curtos. É nesse cenário que ganha relevância a análise das formas de pagamento, buscando responder qual perfil comporta maior exposição ao risco: o cliente que compra exclusivamente à vista, o que opera apenas a prazo ou aquele que alterna entre as duas modalidades.

Ao contrário das taxas de inadimplência, que representam desfechos posteriores e muito suscetíveis a oscilações em poucas compras, a proporção de compras a prazo (PCT_COMPRAS_A_PRAZO) é um indicador pré-fato, definido no momento do pedido. Essa característica a torna uma variável genuinamente explicativa para o modelo. No entanto, embora a intuição de negócio sugira que o risco cresça de forma direta conforme aumenta a dependência do crédito, os dados empíricos apontam para uma dinâmica

diferente, como demonstrado a seguir.

Fig. XX – Impacto da forma de pagamento na inadimplência



Os dados confirmam que os clientes que operam exclusivamente à vista apresentam a menor taxa de risco da carteira (66%), o que é esperado, já que a ausência de concessão de crédito elimina a possibilidade de atraso. O achado contraintuitivo surge ao comparar os clientes que compram exclusivamente a prazo (88% de risco) com aqueles que alternam entre pagamentos à vista e a prazo: esse grupo híbrido atinge o maior nível de risco do estudo, com 97%.

Essa dinâmica evidencia que a relação entre o volume de compras a prazo e o risco não é monotônica. Uma hipótese plausível para o fenômeno é que a variação na forma de pagamento funcione como um sinal indireto de estresse no fluxo de caixa — o cliente costuma pagar à vista, mas recorre ao crédito em momentos pontuais de restrição de liquidez. Embora a análise exploratória não estabeleça relações formais de causalidade, a identificação desse padrão é central para o projeto: trata-se de um comportamento complexo que réguas univariadas e modelos lineares simples não conseguem capturar, fundamentando a necessidade de algoritmos não lineares para a modelagem preditiva.

Como etapa conclusiva da análise do tratamento dos dados antes da modelagem, estabeleceu-se uma auditoria rigorosa na base para evitar viés de memorização e vazamento de informação (data leakage). A primeira regra de governança eliminou integralmente os dados de identificação pessoal e cadastral — como nomes, documentos e contatos —, garantindo que o algoritmo aprenda padrões puramente comportamentais sob anonimização via ID_PESSOA, em vez de memorizar indivíduos específicos.

Em seguida, foram descartadas as variáveis associadas a desfechos operacionais e a componentes aritméticos do próprio alvo. Atributos como o bloqueio do cliente no ERP (FL_BLOQUEADO) representam

--	--	--

--	--	--

uma consequência direta da inadimplência já consumada, enquanto métricas como taxas de atraso e faixas de aging apenas recalculam a definição matemática da variável resposta. A remoção desses campos garante que o modelo não utilize atalhos ou causalidade invertida durante o aprendizado.

A única exceção mantida nessa filtragem foi a inclusão das variáveis de média de dias de atraso (MEDIA_DIAS_ATRASO_PAG/COM), uma decisão consciente cujo valor preditivo real será mensurado empiricamente na etapa de validação. Com a consolidação desses critérios de governança, encerra-se a fase de tratamento dos dados, assegurando um conjunto de atributos metodologicamente consistente e pronto para o treinamento dos algoritmos.

A auditoria de governança confirmou a conformidade da base consolidada (composta por 45 colunas), atestando a ausência completa de dados de identificação nominal e validando o filtro de anonimização. Cumpre ressaltar que a presença de 11 colunas relativas a componentes da variável resposta na base consolidada é intencional, visto que essas métricas são indispensáveis para a caracterização do risco durante a Análise Exploratória de Dados (EDA).

A integridade do pipeline é mantida por meio de travas programáticas que interrompem a execução dos códigos caso haja violações das regras estabelecidas: o Notebook 01 impede a extração de dados nominais, enquanto o Notebook 04 bloqueia a carga caso algum componente do alvo seja indevidamente selecionado como feature. Por fim, para além do isolamento preventivo, o Notebook 08 quantifica empiricamente o impacto das duas variáveis de vazamento mantidas de forma consciente (MEDIA_DIAS_ATRASO_PAG e MEDIA_DIAS_ATRASO_COM), permitindo mensurar com precisão o custo analítico dessa escolha na etapa de modelagem.

4.2 Modelagem Preditiva

Após a etapa de exploração e tratamento dos dados, foram treinados três algoritmos supervisionados para classificação binária:

- Regressão Logística;
- Árvore de Decisão;
- Random Forest.

--	--	--

--	--	--

Para garantir a integridade metodológica e a governança dos dados, o processo de modelagem fundamentou-se na segregação física e lógica da base em duas estruturas independentes e complementares. Essa separação explícita visa mitigar vieses algorítmicos no aprendizado e, simultaneamente, estabelecer a arquitetura de dados necessária para a escoragem (scoring) de risco em ambiente produtivo.

A primeira estrutura, identificada como a visão populacional consolidada (df_ml_completo), abrange a totalidade dos clientes ativos da organização. Ela atua como um barramento de consulta rápida (lookup table) que, em fase de implantação (deploy), servirá de suporte para funções automatizadas de predição individualizada, viabilizando o monitoramento instantâneo do risco de qualquer registro da carteira.

A segunda estrutura, denominada base de aprendizado de máquina (df_treino), é isolada exclusivamente para as etapas de treinamento, validação e teste do algoritmo. Esta partição restringe-se ao histórico de clientes com maturidade transacional bem definida, filtrando novos cadastros para eliminar o ruído provocado pelo problema de início frio (cold-start). Dessa forma, assegura-se que a calibração dos pesos do modelo preditivo ocorra a partir de padrões comportamentais consolidados, otimizando a generalização do classificador.

A divisão da base ocorreu através da estratégia de holdout validation, utilizando:

--	--	--


- 80% dos dados para treinamento;
- 20% dos dados para teste.
- Apenas clientes veteranos, com no mínimo 3 compras

O conjunto de treino e teste foi separado utilizando amostragem estratificada, garantindo equilíbrio proporcional da variável alvo entre as partições.

4.3 Desempenho da Regressão Logística

A Regressão Logística foi utilizada como modelo baseline do projeto. O notebook demonstrou que o modelo apresentou boa interpretabilidade matemática, permitindo identificar coeficientes positivos e negativos associados ao risco. Entretanto, a matriz de confusão revelou desempenho inferior aos demais algoritmos, conforme observado pela matriz de confusão da figura XX abaixo:

Figura 11 - Matriz de Confusão: Regressão Logística



Fonte: Autoria própria

--	--	--

O modelo apresentou:

- 17 falsos negativos;
- dificuldade em separar padrões não lineares;
- baixa capacidade de generalização para perfis complexos.

Esse resultado confirmou que a operação da distribuidora possui relações comportamentais mais complexas do que aquelas capturadas por um modelo linear.

4.4 Desempenho da Árvore de Decisão

A Árvore de Decisão apresentou evolução significativa em relação à Regressão Logística.

Os gráficos da árvore gerados no notebook mostraram regras claras de segmentação, como:

- “SE Média de Dias de Atraso Logístico > 3.5 ”;
- “E Pagamento = A Prazo”;
- “ENTÃO Cliente = Alto Risco”.

O algoritmo conseguiu capturar interações não lineares importantes entre:


- atraso financeiro;
- comportamento logístico;
- modalidade de pagamento;
- frequência de compras.

A árvore alcançou aproximadamente 70 verdadeiros positivos e apenas 5 erros marginais, conforme demonstrado pela matriz de confusão da figura XX abaixo:

--	--	--

--	--	--

Figura 12 - Matriz de Confusão: Árvore de decisão



Apesar da melhora nas métricas, o notebook demonstrou instabilidade durante a validação cruzada, indicando tendência ao overfitting.


--	--	--

--	--	--

4.5 Desempenho do Random Forest

O melhor desempenho do projeto foi alcançado utilizando o algoritmo Random Forest. A técnica de Ensemble Learning demonstrou elevada robustez frente à heterogeneidade dos dados da operação transfronteiriça da empresa. Durante o notebook de treinamento, foi aplicado GridSearchCV para otimização automática dos hiperparâmetros da floresta.

Figura 13 - Matriz de Confusão: Floresta aleatória




Os gráficos de curva ROC desenvolvidos no notebook mostraram excelente capacidade discriminatória do modelo, com curva extremamente próxima ao canto superior esquerdo.

--	--	--

--	--	--

Figura 14 - Curva ROC: Comparação entre os modelos



Fonte: Autoria própria

Isso demonstra a altíssima capacidade do algoritmo em diferenciar clientes saudáveis de clientes potencialmente problemáticos. O baixo número de falsos negativos possui enorme relevância operacional, pois significa que o sistema consegue detectar praticamente todos os clientes com potencial de inadimplência ou retenção logística.

--	--	--


4.6 Importância dos Atributos

Uma das análises mais relevantes realizadas no notebook foi o estudo de importância das variáveis (Feature Importance). O Random Forest identificou como principais variáveis preditivas:

- 1. MEDIA_DIAS_ATRASO_PAG;
- 2. DIAS_DESDE_ULTIMA_COMPRA;
- 3. TICKET_MEDIO;
- 4. MEDIA_DIAS_ATRASO_COM;
- 5. TOTAL_COMODATOS.

Os gráficos de barras gerados pela figura 15 mostraram que o histórico financeiro do cliente possui maior peso na decisão do modelo.

Figura 15 - Análise das importâncias das variáveis por modelo



Fonte: Autoria própria

Além disso, clientes antigos que permaneceram longos períodos sem comprar e posteriormente retornaram realizando pedidos de grande porte apresentaram forte tendência ao risco crítico. A análise interpretativa confirmou matematicamente a hipótese da empresa: o comportamento passado do cliente é o principal indicador do risco futuro.

--	--	--

4.7 Discussão dos Resultados

Os resultados obtidos no notebook demonstraram que a utilização de Machine Learning possui elevado potencial para redução de perdas operacionais na Chopp & Cia. A aplicação do Random Forest permitiu:

- identificar clientes de alto risco antes da aprovação do pedido;
- reduzir possibilidade de retenção de equipamentos;
- diminuir inadimplência financeira;
- automatizar a análise de crédito;
- apoiar decisões comerciais baseadas em dados.

Além disso, as análises exploratórias revelaram padrões estratégicos importantes relacionados à sazonalidade, comportamento financeiro e logística reversa. Os resultados confirmaram a hipótese inicial do projeto, demonstrando que algoritmos Ensemble apresentam desempenho superior em ambientes altamente heterogêneos e ruidosos como o cenário operacional da distribuidora de bebidas na fronteira Brasil–Paraguai.

As análises quantitativas e o desenvolvimento algorítmico atestam indiscutivelmente o valor que o Machine Learning injetará nas veias operacionais da Chopp & Cia. A aplicação rotineira da predição do modelo Random Forest em novos pedidos permite à diretoria.

--	--	--

--	--	--

5 PLANEJAMENTO DE DEPLOY **REFAZER**

O sumário executivo do guia de implantação (*deploy*), manutenção e governança do modelo preditivo de inteligência de risco, desenvolvido para a distribuidora Chopp & Cia no âmbito do Projeto Integrador V da FATEC Votorantim. A solução, fundamentada em um algoritmo de classificação supervisionada *Random Forest*, visa mitigar simultaneamente o risco financeiro e o risco de retenção de ativos em contratos de comodato na granularidade do cliente. A arquitetura tecnológica adota o framework Flask para a construção da API web e utiliza a plataforma de nuvem PythonAnywhere para a hospedagem e disponibilização pública do sistema, cujo detalhamento técnico integral encontra-se anexado a este trabalho.

O núcleo do guia estabelece os procedimentos metodológicos e estruturais necessários para garantir a estabilidade e a integridade da aplicação em ambiente produtivo. Entre os pontos principais, destaca-se a segregação rigorosa entre o conjunto de dados populacional de consulta rápida (*df_ml_completo.csv*) e a base exclusiva de modelagem comportamental de clientes veteranos (*df_treino*), projetada para eliminar o viés de início frio (*cold-start*). O documento normatiza o pipeline de pré-processamento de dados utilizando técnicas de padronização escalar e codificação categórica encadeadas via *scikit-learn*, define uma convenção semântica para o versionamento dos arquivos serializados (*.pkl*) acompanhados de seus respectivos metadados, e padroniza a calibração dinâmica do limiar de decisão (*threshold*) para flexibilizar as ações mitigatórias conforme as prioridades de precisão ou sensibilidade do negócio.

Por fim, o guia delimita as diretrizes de sustentação contínua da inteligência preditiva por meio de rotinas de testes de integridade (via endpoint */health*), monitoramento sistemático contra o fenômeno de deriva de dados (*data drift*) e um ciclo de retreinamento periódico acionado por perdas de desempenho na métrica AUC-ROC. Como considerações prospectivas, a governança do projeto estabelece uma agenda de melhorias focada no refinamento da validação temporal, na incorporação de modelos para novos entrantes e na interpretabilidade algorítmica por meio de valores SHAP. Conclui-se, portanto, que o protocolo de implantação documentado assegura a robustez operacional e a escalabilidade necessárias para subsidiar a tomada de decisão gerencial e proteger as margens de lucro da organização.

--	--	--

--	--	--

6 CONCLUSÃO

A trilha de pesquisa e modelagem técnica do "Projeto Integrador V: Análise Preditiva - Chopp & Cia" consolidou de maneira robusta que as intuições comerciais rudimentares perdem exponencialmente a eficácia frente à complexidade da operação na fronteira sul-mato-grossense.

Ao percorrer todo o Ciclo de Vida da Ciência de Dados — com a identificação e o isolamento contábil de 129 tabelas transacionais cruciais, passando por extensa higienização e culminando na orquestração avançada em árvores de decisão compostas —, a tese original da equipe técnica foi confirmada. O algoritmo de Random Forest (Floresta Aleatória) não apenas neutralizou os ruídos logísticos diários da distribuidora de bebidas, mas escalou para um poder de separação de perfis (AUC-ROC) incrivelmente alto, acima de 97.6%.

A adoção do artefato gerado ataca o epicentro operacional e financeiro da Chopp & Cia, mitigando diretamente o Risco Duplo. Segundo projeções conservadoras baseadas no peso das saídas do código, frear proativamente os 22% dos ofensores identificados pode derrubar os rombos no fluxo de caixa contábil e reduzir o imobilizado de chopeiras roubadas ou inoperantes em aproximadamente 35% ao ano. Ao trocar um demorado e falho "processo no olho" de crédito por uma requisição instantânea via API preenchida com doze features, a gerência escala exponencialmente seu negócio com absoluta paz mental corporativa.

6.1 Próximos Passos

Com o trabalho concluído, ficam apresentadas a seguir as recomendações observadas pelo grupo sobre como elaborar uma segunda fase do trabalho com análises e insights mais robustos e confiáveis para a Distribuidora e também destacar as oportunidades de melhoria da própria base de dados para que o banco seja utilizado com total eficiência assim como um resumo dos principais desafios encontrados para a criação do modelo produzido por este trabalho.

--	--	--

--	--	--

6.2 Evolução Técnica

Para selar a blindagem tecnológica a médio prazo, recomenda-se à administração gerencial avançar com o plano de ação secundário e de manutenção algorítmica (MLOps): 1. Auditoria Prospectiva (Temporal Split): Validar o desempenho do código treinando estritamente em um segmento histórico mais fechado (ex: janelas de 2023) testando a viabilidade de sobrevivência do modelo simulando os dias imprevisíveis dos anos correntes (2025 e diante). 2. Modelagem Heurística (Cold Start): A equação vigente brilha em julgar clientes com vasta quilometragem (os veteranos). É vital projetar e treinar um pipeline secundário ("Radar de Novos Clientes") operando em total ausência de atributos fundamentais como médias de devolução anteriores (MEDIA_DIAS_ATRASO), concentrando os esforços analíticos em dados demográficos ou bureaus de crédito terceiros para a primeira transação.

6.3 Sugestão de Melhorias e Dificuldades Encontradas

É de extrema importância que as informações categóricas dos clientes sejam preenchidas de forma correta para todos os registros, para que possam ser usadas como hiperparâmetros confiáveis na análise realizada via Machine Learning.

A adição de um campo onde conseguimos linkar de forma direta o pedido de comodato com o pedido de venda seria um facilitador primordial. Criar uma documentação das tabelas e dos campos existentes para localizarmos de forma mais prática as informações necessárias e reduzir a necessidade de reuniões para localização de informações.

--	--	--

--	--	--

REFERÊNCIAS

Banco Central del Paraguay (org.). **Reporte de Comércio Exterior**. 2026. Disponível em: <https://www.bcp.gov.py/web/institucional/comercio-exterior-comex->. Acesso em: 16 maio 2026.

BARBOSA, Renan Gonçalves; NOGUEIRA, Ione da Silva Cunha. A EDUCAÇÃO INFANTIL NA FRONTEIRA BRASIL-PARAGUAI: retratos e perspectivas sob a ótica de uma revisão de literatura. **Contrapontos**, Itajaí, v. 1, n. 23, p. 1-18, maio 2024. Disponível em: https://www.researchgate.net/publication/380808450_educacao_infantil_na_frenteira_Brasil-Paraguai_retratos_e_perspectivas_sob_a_otica_de_uma_revisao_de_literatura. Acesso em: 30 abr. 2026.

HASTIE, Trevor; TIBSHIRANI, Robert; FRIEDMAN, Jerome H.. **The elements of statistical learning: data mining, inference and prediction**. 2. ed. na: Springer, 2009.

IBGE. **Panorama do Censo 2022**. Disponível em: <https://censo2022.ibge.gov.br/panorama/?localidade=BR>. Acesso em: 28 abr. 2026.

IBGE. **Produto Interno Bruto dos Municípios**. Disponível em: <https://www.ibge.gov.br/estatisticas/economicas/contas-nacionais/9088-produto-interno-bruto-dos-municipios.html>. Acesso em: 29 abr. 2026.

IPEA. **Atlas do Desenvolvimento Humano no Brasil**. Disponível em: <http://www.atlasbrasil.org.br/consulta/planilha>. Acesso em: 01 maio 2026.

LAMBERTI, Eliana. **Dinâmica comercial no território de fronteira: reexportação e territorialidade na conurbação ponta porã e pedro juan caballero**. 2006. 93 f. Dissertação (Mestrado) - Curso de Geografia, Universidade Federal do Mato Grosso do Sul, Aquidauana, 2006. Disponível em: <https://repositorio.ufms.br/bitstream/123456789/989/1/Eliana%20Lamberti.pdf>. Acesso em: 01 maio 2026.

PARAGUAY. INSTITUTO NACIONAL DE ESTADÍSTICA. (org.). **Indicadores de Población**. Asunción, 2022. 192 p. Disponível em: <https://www.ine.gov.py/resumen/257/resultados-finales-del-censo-nacional-de-poblacion-y-viviendas-2022>. Acesso em: 16 maio 2026.

SLACK, Nigel; CHAMBERS, Stuart; JOHNSTON, Robert. **Administração da Produção**. 8. ed. São Paulo: Atlas, 2018.

--	--	--