

FACULDADE DE TECNOLOGIA DE VOTORANTIM
Curso Superior de Tecnologia em Ciência de Dados

Peterson Alves Pereira
Gabriel Yuji Shimoda

**GUIA DE OPERAÇÃO E MANUTENÇÃO — SISTEMA DE ANÁLISE
PREDITIVA DE INSCRITOS**

Votorantim
2026

SUMÁRIO

1 VISÃO GERAL DAS ROTINAS OPERACIONAIS

2 ATUALIZAÇÃO DOS DADOS (MENSAL)

2.1 Execução do pipeline ETL

2.2 Verificação de integridade

2.3 Renovação do token OAuth2

3 RETREINAMENTO DOS MODELOS (TRIMESTRAL)

3.1 Procedimento de retreinamento

3.2 Critérios de aceitação

3.3 Registro no MLflow

4 MONITORAMENTO DE DRIFT

4.1 Conceito de data drift

4.2 Script de detecção automatizada

4.3 Interpretação dos resultados

4.4 Gatilhos de retreinamento antecipado

5 BACKUP E VERSIONAMENTO

5.1 Dados e datasets

5.2 Credenciais e segurança

5.3 Banco de dados MLflow

6 INDICADORES DE SAÚDE DO SISTEMA

7 TROUBLESHOOTING OPERACIONAL

1 VISÃO GERAL DAS ROTINAS OPERACIONAIS

Este guia descreve as rotinas periódicas necessárias para manter o sistema de análise preditiva atualizado e funcionando corretamente após a implantação inicial. As operações estão organizadas por frequência recomendada e criticidade.

Tabela 1 — Calendário de rotinas operacionais

Rotina	Frequência	Criticidade	Responsável
Atualização de dados (ETL)	Mensal	Alta	Operador / Administrador
Retreinamento de modelos	Trimestral	Média	Cientista de Dados
Monitoramento de drift	Mensal (após ETL)	Alta	Cientista de Dados
Backup de datasets	Após cada coleta	Média	Operador
Renovação de token OAuth2	Sob demanda	Alta	Administrador
Atualização de dependências	Semestral	Baixa	Desenvolvedor

2 ATUALIZAÇÃO DOS DADOS (MENSAL)

A atualização dos dados do canal deve ser realizada mensalmente para manter as projeções alinhadas com o desempenho real do canal. Este é o procedimento mais frequente e crítico para a operação do sistema.

2.1 Execução do pipeline ETL

O procedimento de atualização consiste em:

- Ative o ambiente virtual Python do projeto:

```
source .venv/bin/activate    # Linux/macOS
```

- Execute o pipeline ETL:

```
python src/pipeline/run_pipeline.py
```

O script solicita confirmação do canal, extrai os dados mais recentes via APIs do YouTube e atualiza os arquivos em `data/processed/` e `data/raw/pi6_extracted/`.

2.2 Verificação de integridade

Após a execução do pipeline, verifique a integridade dos dados:

- Confirme que o `dataset_pi6_multivariado.csv` (em `data/processed/`) contém registros até a data esperada e que não há lacunas no período.

- Execute os testes de integridade:

```
python -m pytest tests/integration/test_data_integrity.py -v
```

- Verifique que o número de colunas é 35 e que o período está completo.

2.3 Renovação do token OAuth2

O token OAuth2 (`token.pickle`) é renovado automaticamente pelo pipeline, mas expira periodicamente (tipicamente a cada 7 dias para tokens de desenvolvimento). Se ocorrer erro de autenticação (HTTP 401 ou 403):

- Delete o arquivo `token.pickle` na raiz do projeto
- Execute novamente o pipeline: `python src/pipeline/run_pipeline.py`
- O fluxo OAuth abrirá o navegador para reautenticação
- Após autorizar, o novo token será salvo automaticamente

3 RETREINAMENTO DOS MODELOS (TRIMESTRAL)

A cada trimestre, ou quando houver mudança significativa no comportamento do canal, os modelos devem ser retreinados com os dados mais recentes.

3.1 Procedimento de retreinamento

O retreinamento segue a sequência:

- Certifique-se de que os dados estão atualizados (Seção 2)
- Execute os notebooks de modelagem na seguinte ordem:

```
1. notebooks/modelagem_pi6.ipynb          # Modelagem principal
2. notebooks/modelagem_pi6_robustez.ipynb # Validação cruzada
3. notebooks/mlflow_modelagem_pi6.ipynb   # Registro no MLflow
```

- Atualize as projeções de cenários editoriais com as taxas diárias atualizadas

3.2 Critérios de aceitação

O modelo retreinado deve atender aos seguintes critérios para ser aceito em produção:

- MAPE do SARIMAX no fluxo: abaixo de 1% no holdout de 180 dias
- MAE diário: abaixo de 15 inscritos/dia no fluxo
- Consistência entre folds: desvio padrão do MAPE abaixo de 0,10 p.p.
- Resíduos: autocorrelação dentro dos limites do IC 95%

3.3 Registro no MLflow

Cada retreinamento deve ser registrado como uma nova run no MLflow para rastreabilidade completa. O registro inclui:

- Parâmetros completos (W, H, algoritmo, features, hiperparâmetros)
- Métricas (MAE, RMSE, MAPE, R^2)
- Tags de auditoria (data do retreinamento, motivo, analista responsável)

Para acessar o histórico de runs:

```
mlflow ui --backend-store-uri sqlite:///notebooks/mlflow.db
```

4 MONITORAMENTO DE DRIFT

4.1 Conceito de data drift

Data drift ocorre quando a distribuição estatística dos dados em produção diverge significativamente da distribuição utilizada no treinamento do modelo. No contexto deste projeto, drift pode ocorrer quando:

- O canal viraliza e tem pico atípico de views/inscritos
- O criador muda de formato de conteúdo (ex: para de publicar Shorts)
- O algoritmo do YouTube altera a distribuição de recomendações
- Eventos sazonais (feriados, férias) distorcem as métricas temporariamente

4.2 Script de detecção automatizada

O sistema inclui um script de detecção de drift em `monitoring/drift_detection.py`. O script implementa o método Z-Score shift: compara a média dos últimos 30 dias (janela atual) com a média dos 180 dias anteriores (janela de referência), medindo o desvio em número de desvios-padrão.

Para executar a verificação:

```
python monitoring/drift_detection.py
```

O script analisa automaticamente as variáveis críticas: netSubscribersGained, views, estimatedMinutesWatched e averageViewPercentage.

4.3 Interpretação dos resultados

O script produz um relatório com status para cada variável monitorada:

Tabela 2 — Interpretação do relatório de drift

Status	Z-Score	Significado	Ação
✓ NORMAL	< 2.0	Distribuição estável	Nenhuma ação necessária
⚠ DRIFT_ALERT	≥ 2.0	Desvio significativo	Investigar e avaliar retreinamento

Para cada variável, o relatório exibe: média histórica (referência), média atual, Z-Score shift calculado e status de alerta.

4.4 Gatilhos de retreinamento antecipado

O retreinamento trimestral deve ser antecipado nos seguintes cenários:

- O script de drift detecta DRIFT_ALERT em netSubscribersGained ou views
- O erro do modelo no último mês ultrapassa significativamente o MAE histórico de 11 inscritos/dia no fluxo
- O canal muda drasticamente de estratégia editorial
- O MAPE do modelo em holdout recente ultrapassa 2%

5 BACKUP E VERSIONAMENTO

5.1 Dados e datasets

Os datasets extraídos devem ser versionados no Git após cada coleta. O comando recomendado é:

```
git add data/
git commit -m "data: atualização mensal do dataset (YYYY-MM)"
```

```
git push origin feature/estrutura-padrao-pi6
```

Isso garante rastreabilidade completa e possibilidade de reverter para versões anteriores do dataset em caso de problemas.

5.2 Credenciais e segurança

As credenciais OAuth (client_secret*.json e token.pickle) devem ser mantidas fora do repositório público, em local seguro. O .gitignore já está configurado para ignorar esses arquivos. Recomendações adicionais:

- Nunca comite arquivos .env ou credenciais reais no controle de versão
- Mantenha uma cópia segura do client_secret.json em gerenciador de senhas
- O token.pickle pode ser regenerado a qualquer momento pelo fluxo OAuth

5.3 Banco de dados MLflow

O banco MLflow (notebooks/mlflow.db) pode ser recriado a partir dos notebooks; não é estritamente necessário fazer backup, mas é recomendado manter uma cópia. O .gitignore já ignora o arquivo mlflow.db para evitar conflitos de merge.

6 INDICADORES DE SAÚDE DO SISTEMA

A tabela abaixo resume os indicadores que devem ser monitorados para garantir a saúde operacional do sistema:

Tabela 3 — Indicadores de saúde do sistema

Indicador	Valor Esperado	Frequência de Verificação	Ação se Fora do Limite
MAPE SARIMAX (estoque)	< 1,0%	A cada retreinamento	Investigar drift e retreinar
MAE diário (fluxo)	< 15 subs/dia	A cada retreinamento	Verificar features e dados
Z-Score drift	< 2,0	Mensal (após ETL)	Antecipar retreinamento
Cobertura temporal do dataset	Sem lacunas	Mensal (após ETL)	Reexecutar pipeline
Token OAuth2	Válido	A cada execução ETL	Reautenticar
Backend (porta 8000)	Respondendo	Contínuo	Reiniciar

			container/processo
Frontend (porta 3000)	Respondendo	Contínuo	Reiniciar container/processo

7 TROUBLESHOOTING OPERACIONAL

A tabela abaixo consolida os problemas mais comuns encontrados na operação do sistema e suas respectivas soluções:

Tabela 4 — Problemas comuns e soluções operacionais

Sintoma	Causa Provável	Solução
Pipeline ETL falha com erro 403	Token OAuth expirado ou escopos insuficientes	Delete token.pickle e reautentique pelo fluxo OAuth
MAPE do modelo subiu acima de 2%	Drift no comportamento do canal	Executar drift_detection.py e retreinar com dados recentes
Notebook não encontra dataset	Caminho relativo incorreto ou branch errada	Verificar se está na branch correta e executar git pull
MLflow UI não abre	Porta 5000 ocupada ou mlflow.db corrompido	Mudar porta (--port 5001) ou recriar DB a partir dos notebooks
Frontend não conecta ao backend	Backend não está rodando na porta 8000	Iniciar o backend antes do frontend
Drift detectado em todas as variáveis	Viralização ou mudança algorítmica do YouTube	Aguardar estabilização (1-2 semanas) e retreinar
Projeções muito otimistas/pessimistas	Premissas de cenário inadequadas	Revisar premissas de views no SARIMAX
Testes unitários falhando	Dependência desatualizada ou breaking change	Atualizar dependências: pip install -r requirements.txt