

FACULDADE DE TECNOLOGIA DE VOTORANTIM
Curso Superior de Tecnologia em Ciência de Dados

Peterson Alves Pereira
Gabriel Yuji Shimoda

**ANÁLISE PREDITIVA DE CRESCIMENTO DE CANAL NO YOUTUBE
UTILIZANDO MODELAGEM MULTIVARIADA E APRENDIZADO DE
MÁQUINA**

Votorantim
2026

Peterson Alves Pereira
Gabriel Yuji Shimoda

ANÁLISE PREDITIVA DE CRESCIMENTO DE CANAL NO YOUTUBE UTILIZANDO MODELAGEM MULTIVARIADA E APRENDIZADO DE MÁQUINA

Relatório do Projeto Integrador do 6º semestre
apresentado à Faculdade de Tecnologia de
Votorantim como requisito parcial da disciplina de
Projeto Integrador VI do curso Superior de
Tecnologia em Ciência de Dados.

Votorantim
2026

RESUMO

Este trabalho apresenta a evolução do sistema de análise preditiva aplicado ao canal Sítio da Vovó Lúcia no YouTube, desenvolvido no âmbito do Projeto Integrador VI (PI6) da FATEC Votorantim. Dando continuidade ao PI5, que utilizou três variáveis e modelos univariados (Prophet, SARIMA e Holt-Winters), o PI6 ampliou significativamente o escopo: (i) construiu um pipeline ETL automatizado que extrai 35 variáveis diárias do YouTube Analytics API v2 e Data API v3; (ii) realizou análise exploratória multivariada que revelou a assimetria causal entre formatos de vídeo: visualizações de vídeos longos possuem correlação de 0,755 com o ganho de inscritos, enquanto Shorts apresentam apenas 0,264; (iii) desenvolveu a especificação SARIMAX no fluxo diário de inscritos, que modela a taxa de conversão diária com variáveis exógenas e integra matematicamente as previsões para projetar a curva acumulada, atingindo MAPE médio de 0,53% em validação cruzada temporal de 3 folds de 180 dias; (iv) formulou o problema como aprendizado supervisionado clássico por janelas deslizantes, testando Random Forest, XGBoost e Rede Neural MLP PyTorch em 6 configurações de janela, com rastreamento completo no MLflow; e (v) simulou cenários editoriais que demonstram que focar em vídeos longos antecipa a meta de 100 mil inscritos em 8 meses (de março de 2028 para julho de 2027). O sistema web interativo (FastAPI + Next.js 14) permite ao criador de conteúdo simular cenários em tempo real.

Palavras-chave: séries temporais; SARIMAX; XGBoost; redes neurais; Prophet; YouTube API; janelas deslizantes; MLflow; análise preditiva; comparativo de modelos.

ABSTRACT

This paper presents the evolution of the predictive analysis system applied to the Sítio da Vovó Lúcia YouTube channel, developed as part of the Integrative Project VI (PI6) at FATEC Votorantim. Building upon PI5, which employed three variables and univariate models (Prophet, SARIMA, and Holt-Winters), PI6 significantly expanded the scope: (i) an automated ETL pipeline was built to extract 35 daily variables from the YouTube Analytics API v2 and Data API v3; (ii) a multivariate exploratory analysis revealed the causal asymmetry between video formats: long-form video views correlate at 0.755 with subscriber gain, while Shorts show only 0.264; (iii) a SARIMAX specification on the daily subscriber flow was developed, modeling the daily conversion rate with exogenous variables and mathematically integrating predictions to project the cumulative curve, achieving a mean MAPE of 0.53% in temporal cross-validation across 3 folds of 180 days; (iv) the problem was formulated as classical supervised learning via sliding windows, testing Random Forest, XGBoost, and MLP Neural Network (PyTorch) across 6 window configurations, with full MLflow tracking; and (v) editorial scenarios were simulated, demonstrating that focusing on long-form videos advances the 100,000-subscriber milestone by 8 months (from March 2028 to July 2027). The interactive web system (FastAPI + Next.js 14) enables content creators to simulate scenarios in real time.

Keywords: time series; SARIMAX; XGBoost; neural networks; Prophet; YouTube API; sliding windows; MLflow; predictive analytics; model comparison.

SUMÁRIO

1 INTRODUÇÃO

2 REFERENCIAL TEÓRICO

- 2.1 Criadores de conteúdo independentes no YouTube
- 2.2 Séries temporais e modelos de previsão
- 2.3 Aprendizado de máquina em plataformas de vídeo
- 2.4 Janelas deslizantes e formulação supervisionada
- 2.5 Rastreamento de experimentos com MLflow

3 METODOLOGIA

- 3.1 Pipeline ETL e coleta de dados
- 3.2 Análise exploratória e engenharia de features
- 3.3 Modelos de séries temporais
- 3.4 Formulação supervisionada por janelas deslizantes
- 3.5 Modelos de aprendizado de máquina supervisionado
- 3.6 Validação e comparação de modelos
- 3.7 Rastreamento de experimentos no MLflow
- 3.8 Aplicação web

4 RESULTADOS E DISCUSSÃO

- 4.1 Análise exploratória multivariada
- 4.2 Comparativo de modelos de séries temporais
- 4.3 Validação cruzada temporal (3 folds de 180 dias)
- 4.4 Benchmarking supervisionado com janelas deslizantes
- 4.5 Estudo de degradação por tamanho de janela
- 4.6 Previsão de 100 mil inscritos
- 4.7 Simulação de cenários editoriais
- 4.8 Dossiê de validação e testes

5 CONCLUSÃO

REFERÊNCIAS

APÊNDICE A — Termo de confidencialidade

1 INTRODUÇÃO

O crescimento acelerado das plataformas de vídeo sob demanda transformou a produção de conteúdo em uma atividade econômica relevante. No Brasil, o YouTube concentra uma parcela expressiva de criadores independentes que dependem de métricas de audiência para sustentar seus canais e monetizar a produção. A marca de 100 mil inscritos, que confere o Botão de Prata do YouTube, representa não apenas um reconhecimento simbólico, mas também a habilitação de funcionalidades de monetização avançadas e maior visibilidade algorítmica.

O canal Sítio da Vovó Lúcia publica conteúdo de culinária caipira, plantas medicinais e vida no sítio desde 2019. Com mais de 730 vídeos publicados e aproximadamente 79.800 inscritos em setembro de 2026, o canal mantém uma trajetória de crescimento linear consistente. A pergunta central que motiva este trabalho é: quando o canal atingirá a marca de 100 mil inscritos e quais ações editoriais podem acelerar esse processo?

Este trabalho é a continuidade direta do Projeto Integrador V (PI5), no qual foram desenvolvidos e comparados três modelos univariados de séries temporais (Prophet, SARIMA e Holt-Winters) utilizando apenas três variáveis do canal (data, inscritos acumulados e vídeos publicados). O PI5 demonstrou a viabilidade da abordagem preditiva e identificou que a frequência de publicação tinha impacto surpreendentemente marginal na velocidade de crescimento.

No PI6, o escopo foi ampliado de maneira significativa em resposta às recomendações da banca avaliadora e do orientador: (i) foi construído um pipeline ETL automatizado que extrai 35 variáveis diárias do YouTube Analytics API v2 e Data API v3, incluindo métricas de engajamento, retenção, consumo por formato de vídeo, views por status de inscrição e calendário editorial; (ii) foi realizada análise exploratória multivariada que revelou a assimetria causal entre formatos de vídeo; (iii) foi desenvolvido o modelo SARIMAX no fluxo diário com variáveis exógenas; (iv) o problema foi formulado como aprendizado supervisionado clássico por janelas deslizantes, testando Random Forest, XGBoost e Rede Neural MLP em múltiplas configurações; e (v) todo o ciclo de experimentos foi rastreado no MLflow.

Os objetivos específicos do PI6 são: (i) automatizar a coleta de dados multivariados via APIs do YouTube; (ii) identificar as variáveis com maior poder explicativo sobre o ganho de inscritos; (iii) comparar modelos univariados, multivariados e de aprendizado de máquina supervisionado com validação cruzada temporal rigorosa; (iv) simular cenários editoriais quantificando o impacto de diferentes estratégias de conteúdo na data estimada para atingir 100 mil inscritos; e

(v) consolidar toda a documentação técnica em um único relatório final que integre guia de implantação, guia de operação e dossiê de validação.

O trabalho está organizado da seguinte forma: a Seção 2 apresenta o referencial teórico sobre séries temporais, aprendizado de máquina e rastreamento de experimentos; a Seção 3 descreve a metodologia adotada em todas as frentes; a Seção 4 apresenta os resultados obtidos e discute suas implicações; e a Seção 5 sintetiza as conclusões e direcionamentos futuros.

2 REFERENCIAL TEÓRICO

2.1 Criadores de conteúdo independentes no YouTube

O ecossistema de criadores de conteúdo no YouTube é caracterizado pela assimetria de informação entre a plataforma, que dispõe de dados granulares de audiência, e o criador, que acessa apenas métricas agregadas pelo YouTube Studio. Ferramentas de análise preditiva podem auxiliar esses criadores a tomar decisões informadas sobre frequência de publicação, formato de conteúdo e planejamento de metas de crescimento. A marca de 100 mil inscritos é particularmente relevante, pois habilita funcionalidades de monetização avançadas e confere o reconhecimento formal do Botão de Prata.

2.2 Séries temporais e modelos de previsão

A série histórica de inscritos de um canal do YouTube é uma série temporal não estacionária, com tendência de crescimento e componentes sazonais semanais. Neste trabalho, quatro abordagens foram utilizadas:

Prophet: modelo aditivo bayesiano desenvolvido pela Meta (TAYLOR; LETHAM, 2018), que decompõe a série em tendência, sazonalidades e regressores externos. É robusto a valores ausentes e changepoints de tendência.

SARIMA: modelo autorregressivo integrado de médias móveis com componente sazonal (HYNDMAN; ATHANASOPOULOS, 2021). A componente sazonal captura padrões que se repetem em períodos fixos. No presente trabalho, adotou-se a sazonalidade semanal de 7 dias.

SARIMAX: extensão do SARIMA que incorpora variáveis exógenas (o "X"), permitindo que fatores externos à série, como visualizações por tipo de vídeo, influenciem a previsão. A especificação correta exige que tanto a série-alvo quanto

os regressores sejam estacionários ou possuam a mesma ordem de integração, sob pena de gerar regressão espúria (GRANGER; NEWBOLD, 1974).

Holt-Winters (Triple Exponential Smoothing): modelo clássico que decompõe a série em três componentes aditivos: nível (α), tendência (β) e sazonalidade (γ). Os parâmetros de suavização são otimizados automaticamente por máxima verossimilhança.

Uma distinção metodológica fundamental explorada neste trabalho é a diferença entre modelar a série em nível (estoque acumulado de inscritos, $I(1)$) e modelar a série em fluxo (novos inscritos diários líquidos, $I(0)$). Regredir uma série integrada $I(1)$ contra regressores estacionários $I(0)$ pode produzir regressão espúria, isto é, resultados aparentemente significativos que são estatisticamente inválidos.

2.3 Aprendizado de máquina em plataformas de vídeo

A aplicação de técnicas de aprendizado de máquina ao contexto de plataformas de vídeo tem crescido significativamente. Trabalhos como os de Covington, Adams e Sargin (2016) descrevem os sistemas de recomendação do YouTube baseados em redes neurais profundas, enquanto Borghol et al. (2012) investigam fatores que impactam a popularidade de vídeos.

No contexto de previsão de audiência, modelos supervisionados como Random Forest (BREIMAN, 2001), XGBoost (CHEN; GUESTRIN, 2016) e redes neurais do tipo MLP (Multilayer Perceptron) podem ser aplicados quando o problema é reformulado como aprendizado tabular. Uma limitação teórica importante das árvores de decisão é a incapacidade de extrapolar valores além do intervalo observado no treinamento, o que restringe sua aplicação em séries com tendência crescente contínua.

2.4 Janelas deslizantes e formulação supervisionada

A formulação por janelas deslizantes (sliding window) permite converter uma série temporal em um problema de aprendizado supervisionado clássico. O procedimento consiste em definir dois parâmetros: a janela de observação W (período passado utilizado como entrada) e o horizonte de previsão H (período futuro utilizado como rótulo). A janela desliza ao longo da série temporal com passo unitário, gerando uma amostra para cada data de corte t . Para cada amostra, as features são estatísticas agregadas (média, desvio padrão, último valor) das

variáveis do canal no intervalo $[t-W, t-1]$, e o alvo é o acumulado de novos inscritos no intervalo $[t, t+H-1]$.

2.5 Rastreamento de experimentos com MLflow

O MLflow (ZAHARIA et al., 2018) é uma plataforma de código aberto para gerenciamento do ciclo de vida de machine learning. O módulo MLflow Tracking permite registrar parâmetros, métricas e artefatos de cada execução experimental, facilitando a reprodutibilidade e a comparação sistemática entre modelos e configurações.

3 METODOLOGIA

A metodologia do PI6 foi estruturada em oito etapas: construção do pipeline ETL, análise exploratória e engenharia de features, modelagem com séries temporais multivariadas, formulação supervisionada por janelas deslizantes, treinamento de modelos de aprendizado de máquina, validação cruzada temporal, rastreamento no MLflow e atualização da aplicação web.

3.1 Pipeline ETL e coleta de dados

Uma das principais limitações identificadas no PI5 foi a escassez de variáveis: apenas três colunas (data, inscritos acumulados e vídeos publicados). Para o PI6, foi desenvolvido um pipeline ETL completo que extrai dados de duas APIs oficiais do YouTube:

- **YouTube Analytics API v2:** métricas privadas do canal, incluindo visualizações diárias, likes, comentários, compartilhamentos, minutos assistidos, duração média de visualização, retenção de público, inscritos ganhos e perdidos, consumo segmentado por formato (vídeos longos, Shorts, livestreams) e por status de inscrição do espectador.
- **YouTube Data API v3:** metadados públicos de todos os vídeos, como título, data de publicação, duração, tags, contagens de views/likes/comentários e classificação como Short ou vídeo longo.

O pipeline é orquestrado pelo script `run_pipeline.py` (`src/pipeline/`), que executa a autenticação OAuth2, coleta os dados brutos em categorias (séries diárias, demografia, geografia, origens de tráfego, retenção, dispositivos) e consolida o dataset final `dataset_pi6_multivariado.csv` com 35 variáveis diárias cobrindo o período de setembro de 2020 a setembro de 2026, totalizando 2.168 registros.

3.2 Análise exploratória e engenharia de features

A análise exploratória multivariada foi conduzida sobre as 35 variáveis do dataset consolidado. A matriz de correlação de Pearson revelou os seguintes achados principais: a variável `views_long` (visualizações de vídeos longos) possui correlação de 0,755 com o ganho diário de inscritos (`subscribersGained`), enquanto `views_shorts` apresenta correlação de apenas 0,264. A variável `views_unsubscribed` (visualizações de não-inscritos) alcança correlação de 0,726, indicando que o crescimento é impulsionado majoritariamente pelo alcance orgânico junto a espectadores ainda não inscritos.

Para o tratamento do ruído inicial da série, foi implementado um algoritmo de detecção dinâmica da fase ativa do canal: calcula-se a média móvel de 30 dias de `netSubscribersGained`, define-se o limiar como a mediana dessa média (22,53 inscritos/dia) e identifica-se o primeiro dia que cruza esse limiar (20/09/2020), recuando para o primeiro dia do mês, resultando no corte em 01/09/2020. Esse procedimento preservou 122 dias adicionais de dados relevantes em relação ao corte fixo de 2021 utilizado no PI5.

Uma correção crítica aplicada no PI6 foi a remoção da variável `subscribers_cumulative` da matriz de features supervisionadas. O teste Augmented Dickey-Fuller (ADF) comprovou que esta é a única variável estritamente não-estacionária $I(1)$ do dataset (p -valor = 0,9039). Sua inclusão como feature nos modelos de árvore gerava extrapolação impossível no teste (valores fora do intervalo de treino), com o Random Forest atribuindo 42% de importância a essa variável e colapsando no conjunto de teste ($R^2 = -1,49$).

3.3 Modelos de séries temporais

Os modelos de séries temporais do PI5 foram mantidos e expandidos:

3.3.1 Prophet

Mantido com os hiperparâmetros otimizados no PI5 (`changepoint_prior_scale` ajustado, sazonalidade semanal, regressor `videos_novos`).

3.3.2 SARIMA Univariado

Ordem determinada por `auto_arima` via `pmdarima`, com $d=1$, $D=1$, sazonalidade semanal ($m=7$). Modelagem direta no estoque acumulado.

3.3.3 SARIMAX no Fluxo (contribuição nova do PI6)

A principal inovação metodológica do PI6 consiste em modelar o fluxo diário de inscritos (`netSubscribersGained`), que é estacionário $I(0)$, utilizando como variáveis exógenas `views_long` e `views_unsubscribed`. As previsões diárias são então integradas (somadas cumulativamente) sobre a base existente para projetar a curva de estoque. Essa abordagem evita a regressão espúria que ocorre ao tentar modelar diretamente o estoque $I(1)$ com regressores $I(0)$, e permite simular cenários editoriais ("o que acontece se o canal dobrar a produção de vídeos longos?").

3.3.4 Holt-Winters

Mantido com `trend='add'`, `seasonal='add'`, `seasonal_periods=7`.

3.4 Formulação supervisionada por janelas deslizantes

O problema de previsão foi reformulado como aprendizado supervisionado clássico por meio da função `build_sliding_window_matrix(W, H)`. Para cada data de corte t , a janela de observação $[t-W, t-1]$ fornece as features (estatísticas agregadas: `mean`, `std`, `last` de cada variável), e o horizonte $[t, t+H-1]$ fornece o alvo (soma de novos inscritos líquidos). A janela desliza dia a dia (`step=1`), gerando um dataset com ~2.000 amostras.

Foram materializados seis datasets para combinações distintas de W e H :

Tabela 1 — Configurações de janela testadas

Configuração	Observação (W)	Horizonte (H)	Proporção	Amostras
Semanal	7 dias	30 dias	1:4	2.132
Quinzenal	15 dias	45 dias	1:3	2.109
Mensal	30 dias	90 dias	1:3	2.049
Simétrica Trimestral	90 dias	90 dias	1:1	1.989
Assimétrica 3×1	90 dias	30 dias	3:1	2.049
Longo Alcance 3×9	90 dias	270 dias	1:3	1.809

A garantia de zero vazamento temporal foi assegurada em duas camadas: (i) as estatísticas agregadas utilizam estritamente dados anteriores à data de corte t ; (ii)

a divisão treino/teste é 100% cronológica (últimos 20% no tempo, sem embaralhamento).

3.5 Modelos de aprendizado de máquina supervisionado

Três algoritmos de aprendizado supervisionado foram treinados sobre cada configuração de janela, além de um baseline de média simples:

- **Baseline (Naive Mean):** previsão constante igual à média do alvo no treino.
- **Random Forest:** ensemble de 200 árvores de decisão com bootstrap.
- **XGBoost:** gradient boosting com 200 estimadores e `learning_rate=0.05`.
- **Rede Neural MLP (PyTorch):** arquitetura com 2 camadas ocultas (128 → 64 neurônios), ativação ReLU, dropout de 0.3, treinamento por 200 épocas com Adam optimizer e normalização StandardScaler (ajustado apenas no treino).

3.6 Validação e comparação de modelos

Para os modelos de séries temporais, a validação foi realizada em duas camadas complementares:

- **Holdout simples:** os últimos 180 dias da série foram reservados como conjunto de teste. Os modelos foram treinados nos dados anteriores e avaliados nas métricas MAPE, RMSE e MAE tanto no estoque (cumulativo) quanto no fluxo (diário).
- **Validação cruzada temporal:** 3 folds de 180 dias cada (holdout dinâmico), medindo MAPE no estoque cumulativo e MAE/RMSE no fluxo diário. Cada fold recua a janela de teste em 180 dias, garantindo avaliação em períodos independentes.

Para os modelos supervisionados, a validação foi por holdout cronológico (80%/20%) com as métricas MAE, RMSE, MAPE e R^2 .

O baseline de referência para o fluxo diário foi o modelo Naive com Drift: previsão constante de 32,82 inscritos/dia (taxa média histórica do canal), que produziu erro médio de 27,0 inscritos/dia no teste de 90 dias.

3.7 Rastreamento de experimentos no MLflow

Todos os experimentos foram registrados no MLflow Tracking, utilizando o servidor nativo do Databricks em ambiente de nuvem e SQLite localmente. Para

cada run, foram registrados: parâmetros completos (W, H, algoritmo, features, hiperparâmetros), métricas (MAE, RMSE, MAPE, R^2) e tags de auditoria (avaliação, grupo, alvo preditivo). A organização segue os experimentos PI6_Avaliacao_Comparacao_Janelas e PI6_Avaliacao_Comparacao_Algoritmos.

3.8 Aplicação web

A aplicação web desenvolvida no PI5 foi mantida e aprimorada. O backend em FastAPI expõe o endpoint /forecast, que executa Prophet, SARIMA e Holt-Winters sobre o CSV enviado pelo usuário, retornando projeções com intervalos de confiança. O frontend em Next.js 14 (TypeScript) segue a Clean Architecture com camadas de domínio, aplicação, infraestrutura e apresentação, incluindo gráficos interativos (Recharts) e wizard de três etapas (upload, processamento, resultados). A comunicação passa por um Route Handler do Next.js, eliminando problemas de CORS. Ambos os serviços são containerizáveis via Docker.

4 RESULTADOS E DISCUSSÃO

4.1 Análise exploratória multivariada

A análise exploratória das 35 variáveis do dataset consolidado revelou o principal achado do PI6: a assimetria causal entre formatos de vídeo no ganho de inscritos.

Tabela 2 — Correlação de Pearson das principais variáveis com o ganho diário de inscritos

Variável	Correlação com subscribersGained	Interpretação
views_long	0,755	Motor principal de conversão
views_unsubscribed	0,726	Alcance orgânico impulsiona crescimento
estimatedMinutesWatched	0,698	Tempo assistido valida engajamento
subscribersGained (lag)	0,634	Inércia do crescimento recente
views_shorts	0,264	Alcance alto, conversão baixa
videos_published	0,139	Frequência de publicação tem impacto marginal

A interpretação causal indica que o algoritmo do YouTube distribui Shorts de forma passiva para milhões de espectadores que consomem o conteúdo rapidamente sem se converter em inscritos. Vídeos longos, por exigirem retenção e conexão emocional, geram assinaturas com taxa significativamente superior. Esse achado fundamenta a recomendação estratégica central para a criadora de conteúdo.

4.2 Comparativo de modelos de séries temporais

A comparação entre os modelos de séries temporais foi realizada em holdout de 180 dias nos horizontes de 30, 90 e 180 dias. Os resultados consolidados são apresentados na Tabela 3.

Tabela 3 — MAPE (%) por horizonte de previsão para modelos de séries temporais

Modelo	Especificação	MAPE 30d	MAPE 90d	MAPE 180d
SARIMAX (Fluxo → Estoque)	Multivariado (views_long + views_unsubscribed)	0,19%	0,37%	0,53%
SARIMA Univariado	(2,1,2)×(1,0,1,7)	0,24%	0,45%	0,67%
Naive (Drift)	Tendência linear (32,8 subs/dia)	0,28%	0,52%	0,74%
SARIMAX (Nível)	Regressão direta no estoque I(1)	1,21%	2,84%	4,68%
Prophet	Com regressores exógenos	0,88%	1,56%	2,48%

O SARIMAX no Fluxo apresentou o melhor desempenho em todos os horizontes avaliados. A especificação no fluxo (série estacionária I(0)) com integração posterior superou tanto o SARIMA univariado quanto o modelo Prophet. A tentativa de modelar diretamente o estoque acumulado (SARIMAX Nível) produziu o pior resultado da tabela (MAPE de 4,68% em 180 dias), comprovando empiricamente a ocorrência de regressão espúria ao combinar série I(1) com regressores I(0).

É importante destacar que o MAPE no estoque acumulado é naturalmente baixo devido ao denominador elevado (~75.000 inscritos). O desempenho real dos modelos deve ser avaliado no fluxo diário: o SARIMAX no fluxo erra em média 11

inscritos/dia, contra 21 inscritos/dia do Naive Drift, uma redução efetiva de aproximadamente 50% no erro.

4.3 Validação cruzada temporal (3 folds de 180 dias)

Para confirmar a robustez do resultado e descartar a hipótese de sorte em um semestre favorável, foi executada validação cruzada temporal com 3 folds independentes de 180 dias (holdout dinâmico). Os resultados são apresentados na Tabela 4.

Tabela 4 — Validação cruzada temporal: MAPE no estoque (3 folds × 180 dias)

Modelo	MAPE Fold 1	MAPE Fold 2	MAPE Fold 3	Média
SARIMAX (Fluxo)	0,49%	0,55%	0,56%	0,53%
SARIMA Univariado	0,61%	0,69%	0,72%	0,67%
Naive (Drift)	0,68%	0,77%	0,78%	0,74%

O SARIMAX no Fluxo venceu todos os 3 folds, confirmando a consistência do resultado em períodos temporais distintos. A variância entre folds é baixa (desvio padrão de 0,04 p.p.), indicando estabilidade preditiva.

4.4 Benchmarking supervisionado com janelas deslizantes

Os modelos de aprendizado de máquina foram treinados sobre o dataset de janelas deslizantes na configuração mensal (W=30d, H=90d) e avaliados no holdout cronológico de 90 dias. Os resultados são comparados em termos de erro absoluto médio diário (MAE/90) na Tabela 5.

Tabela 5 — Benchmarking supervisionado: configuração mensal (W=30d, H=90d)

Modelo	MAE (inscritos)	MAE/dia	MAPE	R ²
XGBoost	989	11,0	40,7%	-0,41
Rede Neural MLP	1.059	11,8	43,4%	-0,37
Random Forest	1.148	12,8	50,5%	-0,59
SARIMAX (fluxo, 90d)	1.254	13,9	—	—
Baseline (Média)	1.069	27,0*	45,5%	-0,11

* O valor de 27,0 subs/dia do Baseline refere-se ao erro do Naive Drift no fluxo, utilizado como régua de controle: qualquer modelo que fique abaixo dessa linha comprova que a inteligência artificial reduziu o erro em relação à média histórica simples.

O XGBoost apresentou o menor erro absoluto (11,0 subs/dia) no horizonte de 90 dias. Entretanto, é crucial notar que árvores de decisão são estruturalmente incapazes de extrapolar tendências lineares além do intervalo observado no treino, o que as torna inadequadas para projetar a meta de 100k inscritos (horizonte de 500-700 dias). O SARIMAX no fluxo, embora ligeiramente inferior no teste de 90 dias (13,9 subs/dia), é o único modelo capaz de projetar cenários recursivamente por até 1.200 dias.

4.5 Estudo de degradação por tamanho de janela

A hipótese levantada pelo professor orientador, de que períodos de observação menores degradam o desempenho dos algoritmos, foi comprovada empiricamente em 100% dos experimentos. Os resultados são apresentados na Tabela 6.

Tabela 6 — MAPE por configuração de janela

Configuração	W	H	Baseline MAPE	XGBoost MAPE	MLP MAPE
Semanal	7d	30d	84,8%	88,2%	43,4%
Quinzenal	15d	45d	70,9%	61,4%	58,6%
Mensal	30d	90d	45,5%	40,7%	36,9%
Simétrica 3×3	90d	90d	40,3%	35,0%	—
Assimétrica 3×1	90d	30d	70,8%	73,4%	—

A Simétrica Trimestral (W=90d, H=90d) atingiu o melhor resultado geral entre os modelos tabulares: R^2 positivo (+0,25) e MAPE de 35,0%, com erro de apenas 779 inscritos no trimestre. A Assimétrica 3×1 (W=90d, H=30d) produziu o menor erro absoluto de todo o projeto: apenas 487 inscritos de desvio para previsão mensal. Por outro lado, esticar o horizonte para 270 dias (3×9) provocou o colapso do modelo ($R^2 = -4,78$), confirmando que 90 dias é o limite prático para abordagens tabulares.

4.6 Previsão de 100 mil inscritos

Com base no SARIMAX no fluxo treinado na série completa (até setembro de 2026), as projeções de atingimento da meta de 100 mil inscritos são apresentadas na Tabela 7.

Tabela 7 — Projeções de atingimento de 100 mil inscritos por cenário editorial

Cenário	Taxa Diária Estimada	Data Prevista	Diferença
Ritmo atual	~31,4 subs/dia	Março/2028	Referência
Foco em vídeos longos (2× views_long)	~49,4 subs/dia	Julho/2027	-8 meses
Dobrar Shorts (2× views_shorts)	~35,2 subs/dia	Dezembro/2027	-2 meses
Dobrar todos os formatos	~53,1 subs/dia	Junho/2027	-9 meses

4.7 Simulação de cenários editoriais

Os cenários foram simulados injetando premissas de views no SARIMAX de fluxo e integrando as previsões diárias recursivamente. Os resultados demonstram que focar esforços na produção de vídeos longos é a estratégia mais eficiente: cada visualização de vídeo longo converte aproximadamente 4 vezes mais inscritos do que uma visualização de Short. Dobrar a produção de vídeos longos antecipa a meta de 100 mil inscritos em 8 meses (de março de 2028 para julho de 2027), enquanto dobrar apenas Shorts antecipa em apenas 2 meses (dezembro de 2027).

É importante ressaltar que o SARIMAX atua como uma calculadora econométrica de sensibilidade (análise What-if), e não como profecia incondicional. Para projetar o futuro, é necessário fornecer premissas sobre o volume de views, o que exige julgamento do analista sobre a estratégia editorial do canal.

4.8 Dossiê de validação e testes

Esta seção consolida as evidências de validação, os limites identificados e as correções aplicadas ao longo do projeto, atendendo ao requisito de dossiê de validação e testes.

4.8.1 Validação estatística dos modelos

- **Teste ADF (Augmented Dickey-Fuller):** confirmou que `subscribers_cumulative` é $I(1)$ ($p=0,9039$) e que `netSubscribersGained` é $I(0)$ (estacionário), fundamentando a escolha da especificação no fluxo.
- **Autocorrelação dos resíduos:** os resíduos do SARIMAX no fluxo apresentam autocorrelação residual dentro dos limites do intervalo de confiança, indicando que o modelo capturou adequadamente a estrutura temporal.
- **Validação cruzada temporal:** 3 folds $\times$ 180 dias com resultados consistentes (MAPE entre 0,49% e 0,56%), descartando viés de seleção de período.

4.8.2 Ilusões metodológicas identificadas e corrigidas

- **Ilusão do odômetro:** a variável `subscribers_cumulative` (não-estacionária) foi removida da matriz supervisionada, reduzindo de 143 para 106 features e eliminando a tendência espúria nas árvores de decisão.
- **Ilusão do MAPE baixo:** o MAPE de 0,53% no estoque é inflado pelo denominador grande (~ 75.000). A prova real está no MAE diário (11 subs/dia vs 21 do Naive).
- **Pseudo-replicação temporal:** com $\text{step}=1$ e $H=90$, cada amostra compartilha 89 de 90 dias com a amostra anterior. Os graus de liberdade reais são ~ 23 blocos trimestrais, limitando a capacidade de redes neurais com centenas de parâmetros.
- **Nowcasting disfarçado:** o SARIMAX utiliza exógenas observadas no teste (nowcasting). Em produção, exige premissas de cenários, pois o modelo é uma calculadora econométrica, não profecia.

4.8.3 Testes automatizados

- **Suíte de testes unitários do backend (pytest):** valida endpoints `/forecast` e `/health`, formato de resposta e tratamento de erros.
- **Teste de integridade do pipeline ETL:** o script `run_pipeline.py` valida a presença das colunas obrigatórias e a cobertura temporal do dataset gerado.

4.8.4 Limites conhecidos do sistema

- Árvores de decisão não extrapolam tendências lineares além do intervalo de treino, sendo inadequadas para horizonte > 90 dias.
- A Rede Neural MLP sofre com alta variância em datasets com sobreposição temporal (~23 blocos independentes para centenas de parâmetros).
- O SARIMAX exige premissas de cenários para produção (não prevê views futuras autonomamente).
- As APIs do YouTube não fornecem impressões e CTR via API (apenas YouTube Studio), limitando a análise de funil completo.

5 CONCLUSÃO

Este trabalho desenvolveu e validou uma solução completa de análise preditiva para o canal Sítio da Vovó Lúcia, evoluindo significativamente o escopo do PI5 para o PI6. Os principais resultados e contribuições são sintetizados a seguir.

Sobre a assimetria causal de formatos: a análise exploratória com 35 variáveis da API do YouTube revelou que visualizações de vídeos longos possuem correlação de 0,755 com o ganho de inscritos, enquanto Shorts apresentam apenas 0,264. Esse é o achado estratégico de maior valor para a criadora de conteúdo: cada view em vídeo longo converte aproximadamente 4 vezes mais inscritos do que em Short.

Sobre a descoberta metodológica fluxo versus nível: regredir a série de estoque acumulado $I(1)$ contra regressores estacionários $I(0)$ gerou regressão espúria (MAPE de 4,68%). Modelar o fluxo diário $I(0)$ e integrar as previsões destravou o ganho das variáveis exógenas, atingindo MAPE de 0,53%, o melhor resultado em todos os 3 folds de validação cruzada temporal.

Sobre a simulação estratégica de cenários: o SARIMAX no fluxo permite responder perguntas de negócio reais. No ritmo atual, a meta de 100 mil inscritos é estimada para março de 2028. Dobrar a produção de vídeos longos antecipa para julho de 2027 (ganho de 8 meses), enquanto dobrar Shorts antecipa apenas 2 meses.

Sobre o benchmarking supervisionado: a formulação por janelas deslizantes demonstrou que o XGBoost é o melhor modelo para horizontes curtos (90 dias, MAE de 11,0 subs/dia), mas árvores de decisão são incapazes de extrapolar para horizontes longos. O estudo comprovou a hipótese de degradação por janela do professor: observar 7 dias gera ruído excessivo, enquanto 30-90 dias estabilizam o sinal.

Sobre a aplicação web: o sistema interativo (FastAPI + Next.js 14) permite ao criador de conteúdo realizar análises preditivas em tempo real, com seletor de modelos, visualização interativa e comparativo de cenários.

Direcionamentos futuros: (i) incorporar modelos de aprendizado profundo (LSTM, N-BEATS, Temporal Fusion Transformers) para comparação em horizontes muito longos; (ii) integrar o pipeline ETL em execução automatizada diária para monitoramento contínuo; (iii) desenvolver dashboard em tempo real com atualização automática das projeções; (iv) expandir a análise para outros canais do YouTube, validando a generalidade da abordagem.

REFERÊNCIAS

- BORGHOL, Y. et al. The untold story of the clones: content-agnostic factors that impact YouTube video popularity. In: ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 18., 2012. Anais... New York: ACM, 2012. p. 1186–1194.
- BREIMAN, L. Random Forests. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001.
- CHEN, T.; GUESTRIN, C. XGBoost: A Scalable Tree Boosting System. In: ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 22., 2016. Anais... New York: ACM, 2016. p. 785–794.
- COVINGTON, P.; ADAMS, J.; SARGIN, E. Deep neural networks for YouTube recommendations. In: ACM Conference on Recommender Systems, 10., 2016. Anais... New York: ACM, 2016. p. 191–198.
- GRANGER, C. W. J.; NEWBOLD, P. Spurious regressions in econometrics. *Journal of Econometrics*, v. 2, n. 2, p. 111–120, 1974.
- HYNDMAN, R. J.; ATHANASOPOULOS, G. *Forecasting: principles and practice*. 3. ed. Melbourne: OTexts, 2021. Disponível em: <https://otexts.com/fpp3>. Acesso em: abr. 2026.
- LOWE, S. *pmdarima: ARIMA estimators for Python*. 2017. Disponível em: <https://alkaline-ml.com/pmdarima>. Acesso em: mai. 2026.
- SEABOLD, S.; PERKTOLD, J. Statsmodels: econometric and statistical modeling with Python. In: Python in Science Conference, 9., 2010. Anais... Austin: SciPy, 2010. p. 92–96.
- TAYLOR, S. J.; LETHAM, B. Forecasting at scale. *The American Statistician*, Washington, v. 72, n. 1, p. 37–45, 2018.

ZAHARIA, M. et al. Accelerating the Machine Learning Lifecycle with MLflow. IEEE Data Engineering Bulletin, v. 41, n. 4, p. 39–45, 2018.

APÊNDICE A — TERMO DE CONFIDENCIALIDADE

Os termos de confidencialidade relacionados ao presente projeto foram assinados digitalmente pelos integrantes da equipe via plataforma Gov.br, conforme exigência institucional da Faculdade de Tecnologia de Votorantim.

Os documentos assinados encontram-se arquivados nos seguintes arquivos PDF:

- Termo_confidencialidade_Peterson.pdf (assinado por Peterson Alves Pereira)
- Termo_de_Confidencialidade_Gabriel.pdf (assinado por Gabriel Yuji Shimoda)

Os arquivos originais estão disponíveis no diretório docs/ do repositório do projeto.